

Université Paris Dauphine — PSL
Master 2 Ingénierie statistique et financière

Complémentarité d'un linker SNOMED à dictionnaire et d'un linker dense

*Borne oracle au niveau mention
et file de relecture sans vérité terrain*

Mémoire de fin d'études

Ahmed ABATNA

Tuteur académique : Pierre Fihey
Maître d'apprentissage : Asma Rabaoui

Année universitaire 2025–2026

Table des matières

Remerciements	8
Résumé	9
Abstract	10
Liste des acronymes	11
Introduction	12
Contexte et enjeux	12
Problématique	12
Démarche	13
Principaux résultats	14
Organisation du mémoire	14
1 Cadre institutionnel, données et métriques	15
1.1 Notes cliniques et EDS	15
1.2 SNOMED CT, en ce qu'il sert ici	15
1.3 MIMIC-IV-Note et le jeu du challenge	16
1.4 La métrique du challenge, et celle que nous ajoutons	17
1.4.1 mIoU caractère, macro par concept	17
1.4.2 Rappel mention	17
1.5 Deux pipelines, un même format de sortie	17
1.6 Ce que « reproduction » veut dire ici	17
1.7 Contraintes matérielles et choix qu'elles imposent	18
1.8 Anatomie d'une note de sortie MIMIC	18
1.9 Les trois branches SNOMED du challenge	19
1.10 Granularité, polysémie, abréviations	19
1.11 Synthèse du chapitre	20
2 Revue de la littérature et positionnement	21
2.1 Deux pipelines, un même gold	21
2.2 Ce que JAMIA a déjà établi	21
2.3 Hybride d'architecture et hybride de décision	22

2.4	Cadre : classification sélective et borne oracle	22
2.5	Positionnement	23
2.6	Synthèse du chapitre	23
3	Reproduction des deux pipelines	24
3.1	Dictionnaire : principe	24
3.2	La solution KIRIs publiée	24
3.3	Ce que nous avons réellement inféré	25
3.4	Le dictionnaire statique de SnoBERT, à ne pas confondre	25
3.5	Propriétés du dictionnaire reproduit	26
3.6	Algorithme d'inférence, pas à pas	26
3.7	Construction de la table sur le train	26
3.8	Coût et auditabilité	27
3.9	SnoBERT : NER, retrieval et post-traitement	27
3.10	Stage 1 — reconnaissance d'entités	27
3.11	Stage 2 — linking par proximité de libellés	28
3.12	Post-traitement : le dictionnaire déjà dans S	28
3.13	Score hold-out utilisé ensuite	29
3.14	Ensembling du stage 1	29
3.15	Pourquoi SnoBERT n'est pas « le neural pur »	29
3.16	Synthèse du chapitre	29
4	Méthodologie : alignement, oracle et file de relecture	30
4.1	But	30
4.2	Alignement mention à mention	30
4.3	Cinq régimes	30
4.4	Oracle : un plafond, pas une méthode	31
4.5	File de relecture sans gold	31
4.6	Décomposition du rappel d'erreurs	32
4.7	Option B (contrôle, pas un chapitre parallèle)	32
4.8	Distance d'édition, descripteur et non linker	32
4.9	Ce que nous n'avons pas fait	32
4.10	Invariants et tests	33
4.11	Synthèse du chapitre	33
5	Résultats empiriques	34

5.1	Scores globaux et borne oracle	34
5.2	Table des régimes	34
5.3	Efficacité de la file	35
5.4	Exemples	36
5.5	Voisinage morphologique des conflits	37
5.6	Option B, en une sous-section	39
5.7	Lecture	39
5.8	Lecture EDS des effectifs	39
5.9	Comparaison qualitative à un vote	40
5.10	Stabilité à $n = 32$ notes	40
5.11	Synthèse du chapitre	40
6	Application : interfaces Streamlit	41
6.1	Rôle de ce chapitre	41
6.2	Deux modes	41
6.3	Captures (mode laboratoire)	41
6.4	Ce que l'écran colorie	43
6.5	Limites	43
6.6	Synthèse du chapitre	44
7	Conclusion et perspectives	45
7.1	Synthèse des apports	45
7.1.1	Apports méthodologiques	45
7.1.2	Apports empiriques	45
7.1.3	Positionnement par rapport à la littérature	45
7.2	Limites du travail	46
7.3	Perspectives	46
7.4	Conclusion finale	46
A	Protocole figé et formules	49
A.1	Décisions figées	49
A.2	Commandes	49
B	Option B (contrôle)	50
C	Exemple pédagogique : une note imaginaire de dix mentions	51

D	Glossaire opérationnel	52
E	Arborescence utile	53
F	Compléments sur SNOMED CT et le périmètre	54
G	Compléments sur la métrique caractère	55
H	Jeux de nombres à ne pas mélanger	56
I	Remarques de reproductibilité statistique	57

Table des figures

3.1	Pipeline SnoBERT tel qu'inféré.	27
4.1	Les cinq régimes. Seul l'ACCORD sort de la file de relecture.	30
5.1	Les 1 282 erreurs. La file voit les deux premiers blocs (71 %). Le troisième lui échappe.	36
6.1	Interface SnoBERT (<code>app_snobert.py</code>), note 10989002-DS-3 du hold-out. Vert : span prédit qui chevauche le gold ; jaune : prédiction absente du gold ; rouge : annotation manquée. Le F1 affiché repose sur un matching d'offsets, distinct de l'IoU $\geq 0,5$ et de l'égalité des SCTID.	42
6.2	Interface dictionnaire, note 10043750-DS-6 (corpus d'entraînement, 240 notes). Même code couleur. Cette note n'appartient pas au hold-out des tables principales.	43

Liste des tableaux

1.1	Échelle du challenge SNOMED CT Entity Linking [3].	16
1.2	Split utilisé dans ce mémoire (notes cutmed, graine 42).	16
3.1	Qualité du retrieval SapBERT seul (spans gold).	28
5.1	Option A — scores globaux. L’oracle voit le gold.	34
5.2	Option A — régimes. $P(\text{erreur}) = 1 - \mathbb{P}(\text{hit oracle})$	34
5.3	File de relecture (émettre l’union, relire le non-accord).	35
5.4	Décomposition des 1 282 erreurs par régime.	36
5.5	Exemples d’alignement (option A). FSN raccourcis (tag sémantique omis).	37
5.6	Distance d’édition entre FSN de D et de S , mentions en CONFLIT ($n = 506$). Trois conflits n’ont pas de FSN S dans le snapshot.	38
5.7	Les motifs « morpho voisin » du hold-out (7 mentions, 5 paires).	38
B.1	Option B — scores globaux.	50
B.2	Option B — régimes.	50
H.1	Deux protocoles, deux mIoU SnoBERT. Ne pas les additionner.	56

Remerciements

Je remercie Pierre Fihey d’avoir accepté d’encadrer ce mémoire. Il m’a laissé une large autonomie sur un sujet à l’interface du traitement automatique de la langue et de la décision statistique ; les points que nous en avons discutés m’ont aidé à en fixer le cadre.

Je remercie Enovacom de m’avoir accueilli en alternance et de la confiance qui m’a été accordée. Au sein de l’entreprise, je remercie tout particulièrement Asma Rabaoui, maître d’apprentissage, pour l’encadrement, la disponibilité et le soutien qu’elle m’a apportés tout au long de l’année.

Je remercie Pierre Brugière, responsable du Master ISF à l’Université Paris Dauphine — PSL, pour la tenue du parcours et l’exigence des enseignements.

Mes remerciements s’adressent aussi aux enseignantes, aux enseignants et à l’équipe pédagogique du Master, qui m’ont donné les outils et les réflexes de l’année, ainsi qu’à Adel, Elimane et Mouhamadou, camarades de promotion, pour les discussions qui ont accompagné le quotidien.

Enfin, je remercie ma famille, mes frères et sœurs, et mes proches, pour leur soutien constant.

Résumé

Le linking d'entités cliniques consiste à repérer un span dans une note hospitalière et à lui associer un identifiant SNOMED CT parmi plusieurs centaines de milliers de concepts. Le challenge DrivenData, synthétisé par Davidson et al. dans JAMIA [3], a établi que le meilleur dictionnaire (KIRIs) et le meilleur pipeline dense (SnoBERT) sont statistiquement indiscernables au niveau du *concept*, et qu'un vote des vainqueurs n'apporte que +0,022 de mIoU.

On se place au niveau de la *mention*. Sur un hold-out de 32 notes (8 599 annotations), on aligne une reproduction partielle du dictionnaire de KIRIs — lookup (*section, mention*) appris sur le train, sans OMOP ni table d'abréviations — et SnoBERT complet. La solution publiée par KIRIs utilise également OMOP, des abréviations et des règles ; ces fichiers n'étaient pas disponibles, de sorte que le système *D* évalué ici ne les contient pas. Un sélecteur qui verrait la vérité terrain et retiendrait, à chaque occurrence, le ticket correct lorsqu'il existe (oracle) porterait le rappel mention de 0,768 (SnoBERT) à 0,851. Environ 15 % des mentions restent hors d'atteinte des deux pipelines. Le mIoU caractère de cet oracle (0,72) est trompeur, car l'oracle n'émet que des vrais positifs : le chiffre pertinent pour un entrepôt de données de santé est le rappel.

En production, la vérité terrain n'est pas disponible. L'accord entre les deux sorties, en revanche, l'est. La politique retenue, afin de ne pas sacrifier le rappel, consiste à émettre l'union des tickets et à relire tout ce qui n'est pas un accord. Cette file représente 28,3 % des mentions et 71,1 % des erreurs. Parmi ces 71 points, 41 proviennent du silence (AUCUN : aucun span n'a été proposé, donc erreur automatique) et environ 30 d'un désaccord au sens strict. Il demeure 370 erreurs dans le régime d'accord (29 % des erreurs) : les deux systèmes se trompent de la même manière, et la file ne les voit pas.

Le mémoire n'introduit pas de nouveau modèle. Il propose un cadre de risque et de couverture pour une file d'annotation, dans la lignée de la classification sélective [2, 5].

Mots-clés : entity linking clinique, SNOMED CT, dictionnaire, SnoBERT, complémentarité, oracle, prédiction sélective, file de relecture.

Abstract

Clinical entity linking finds a span in a note and maps it to a terminology concept — here SNOMED CT, limited to findings, procedures and body structures. The DrivenData / JAMIA 2025 challenge showed that the winning dictionary (KIRIs) and the winning dense pipeline (SnoBERT) are statistically indistinguishable at concept level, and that majority vote of the winners yields only +0.022 mIoU.

This thesis examines the mention rather than the concept. On a 32-note hold-out (8,599 gold mentions), KIRIs’s dictionary is aligned — a partial reproduction : the (*section, mention*) lookup trained on cutmed, without OMOP or abbreviations — with full SnoBERT. The published KIRIs solution also uses OMOP, abbreviations and extra rules ; those assets were unavailable, so *D* does not include them. An oracle that always kept the correct ticket would raise mention recall from 0.768 (SnoBERT) to 0.851. About 15% of mentions remain out of reach. The oracle’s character mIoU (0.72) is inflated, because it emits only true positives ; for a decision-support desk, mention recall is the figure that matters.

Without gold, that oracle is unavailable. Agreement, however, can be read off the two outputs. The policy retained is recall-oriented : emit the union of tickets, review everything that is not agreement. The queue is 28.3% of mentions and contains 71.1% of the errors. Of those 71 points, 41 come from silence (neither system proposed a span) and about 30 from genuine disagreement. 370 errors (29%) stay in the agreement regime ; the queue never sees them.

The contribution is not a new linker, but a risk–coverage reading of a review queue, in the line of selective classification.

Keywords : clinical entity linking, SNOMED CT, dictionary matching, SnoBERT, complementarity, oracle bound, selective prediction, review queue.

Liste des acronymes

BIO	schème d'étiquetage Begin / Inside / Outside
CPU	processeur (inférence dictionnaire)
EDS	entrepôt de données de santé
EL	<i>entity linking</i>
GPU	processeur graphique
IAA	accord inter-annotateurs (<i>inter-annotator agreement</i>)
IoU	<i>Intersection over Union</i>
JAMIA	<i>Journal of the American Medical Informatics Association</i>
KIRIs	équipe vainqueur du challenge (dictionnaire)
LLM	grand modèle de langue
MIMIC	<i>Medical Information Mart for Intensive Care</i>
mIoU	IoU caractère moyenne (macro par concept)
NER	<i>named entity recognition</i>
OMOP	<i>Observational Medical Outcomes Partnership</i>
Q1, Q2	questions de recherche (borne oracle ; file sans gold)
SCTID	identifiant SNOMED CT
SNOMED CT	<i>Systematized Nomenclature of Medicine — Clinical Terms</i>
UMLS	<i>Unified Medical Language System</i>

Introduction

Contexte et enjeux

Une part substantielle de l'information hospitalière n'est pas stockée dans des tables. Elle figure dans les notes : comptes rendus d'entrée, lettres de sortie, observations du jour. Pour qu'un entrepôt de données de santé puisse dénombrer des cas ou constituer une cohorte reproductible, il faut coder, c'est-à-dire associer à une phrase un identifiant stable.

SNOMED CT est l'une de ces terminologies. Chaque concept possède un numéro (SCTID), des libellés et une place dans une hiérarchie. Relier « hypertension » à 38341003 permet à deux rédacteurs, dans deux établissements, de désigner la même entité pour le moteur de requête.

On appelle cette opération l'*entity linking* clinique. Elle enchaîne deux gestes : localiser le span, puis lui attribuer un SCTID parmi des centaines de milliers de candidats. Dans le score du challenge DrivenData, ces deux erreurs se ressemblent : un span trop court (« kidney » au lieu de « left kidney lesion ») et un mauvais code sur un span correct dégradent l'un comme l'autre l'IoU caractère.

En 2024, DrivenData, SNOMED International et PhysioNet ont organisé un challenge d'entity linking sur des notes MIMIC-IV annotées [4]. L'article de Davidson et al. dans JAMIA [3] en fixe l'échelle : 74 808 annotations, 272 notes, 6 624 concepts ; un accord inter-annotateurs Jaccard d'environ 0,85, qui donne un plafond humain au mIoU ; KIRIs à 0,4202 et SNOBERT à 0,4194 en privé, avec des intervalles de confiance à 95 % qui se recouvrent ; un vote majoritaire des trois vainqueurs qui ne gagne que +0,022. Au niveau du concept, fusionner les vainqueurs rapporte donc très peu. Relancer un hybride dans le seul but de « battre 0,42 » reviendrait à se placer après cet article.

Problématique

JAMIA n'a pas travaillé au grain de la mention. Qu'un concept soit difficile pour les deux systèmes n'interdit pas, sur une occurrence donnée, que le dictionnaire retrouve « hypotension » et que SnoBERT retrouve « lap chole ». L'article ne distingue pas non plus le vote (toujours fusionner) de l'abstention (savoir quand ne pas faire confiance). Enfin, il ne cherche pas de signal utilisable sans vérité terrain : en production, personne n'indique lequel des deux tickets est le bon.

Deux questions, notées Q1 et Q2, structurent le travail.

Q1 est une question de laboratoire. Sur un hold-out de 32 notes et 8 599 mentions gold, on compare deux systèmes. *D* est une reproduction partielle du dictionnaire de KIRIs : une

table (en-tête, mention) $\mapsto$ SCTID majoritaire du train. Ce n'est pas la solution complète de l'équipe (0,4202 en privé), qui utilise également OMOP, une table d'abréviations et des règles ; ces fichiers n'étaient pas disponibles. S est SnoBERT complet (NER, SapBERT, dictionnaire statique). Si un sélecteur voyait le gold et retenait, à chaque mention, le ticket juste parmi $\{D, S\}$ lorsqu'il existe, de combien le rappel mention augmenterait-il par rapport au meilleur des deux ? Un écart net indiquerait que les erreurs ne portent pas sur les mêmes occurrences. Un écart nul indiquerait qu'il n'y a presque rien à gagner, même au grain mention.

Ce sélecteur est appelé *oracle* : il connaît la vérité terrain. Ce n'est pas un troisième linker, et il n'est pas déployable. On note

$$\Delta_{\text{oracle}} = R_{\text{oracle}} - \max(R_D, R_S)$$

le gain de rappel mention sous cet arbitre. C'est un plafond de complémentarité, non un score de production.

Q2 se pose sans gold. L'accord se lit sur les sorties. Peut-on s'en servir pour une file : émettre l'union des tickets, relire ce qui n'est pas un accord ? Quelle part des erreurs cette file attrape-t-elle, et quelle fraction de ce chiffre vient simplement du silence (AUCUN) ?

Trois hypothèses, falsifiables, encadrent l'interprétation. H1 : le Δ_{oracle} de rappel est de plusieurs points, et non un écart de 10^{-3} . H2 : le non-accord est plus souvent erroné que l'accord. H3 : une partie du rappel d'erreurs de la file est du silence ; le 71 % doit se lire 41 + 30, et non comme un succès du seul désaccord.

Le mémoire ne construit pas une nouvelle architecture. Il ne démontre pas qu'une cascade dictionnaire-puis-Transformer est supérieure. KIRIs et SnoBERT sont reproduits, non conçus. L'apport propre tient à l'alignement mention à mention, à la borne oracle, aux cinq régimes, à la file de relecture et aux tables qui en découlent. Les applications Streamlit visualisent les spans d'un système, en live ou contre le gold ; elles ne constituent pas le résultat principal.

Démarche

Le protocole est figé sur le hold-out déjà utilisé pour `submission_baseline.csv`. L'alignement retient, pour chaque mention gold, le ticket de D (resp. S) de meilleur IoU de span, s'il est au moins 0,5. Un hit exige en outre le bon SCTID. Cinq régimes partitionnent les mentions. L'oracle retient le ticket hit lorsqu'il existe. La file, sans gold, est le complémentaire de l'accord. Le code est dans `oracle_study/`, avec des tests d'invariants.

Principaux résultats

Sur les 8 599 mentions du hold-out, les scores sont les suivants.

Le meilleur système seul est SnoBERT, avec un rappel mention de 0,768. L’oracle atteint 0,851, soit $\Delta_{\text{oracle}} = +8,3$ points. Environ 15 % des mentions ne sont sauvées par personne. Il existe 517 mentions justes seulement chez KIRIs et 554 seulement chez SnoBERT : les erreurs ne sont pas aux mêmes endroits. H1 n’est pas rejetée.

La file unique (émettre l’union, relire le non-accord) représente 28,3 % du volume et 71,1 % des erreurs. En suivant H3, on décompose : 41 points de silence, 30 de désaccord stricto sensu, 29 d’accords faux. Le désaccord au sens strict n’attrape que 30 % des erreurs, et non 71. H2 n’est qu’à moitié vérifiée : le non-accord n’est pas homogène ; le conflit a une erreur à 0,115, proche des 0,060 de l’accord, alors que D-SEUL atteint 0,30.

Le mIoU caractère de l’oracle (0,72) n’est pas le gain opérationnel : l’oracle n’émet que des vrais positifs et écarte ainsi les faux positifs de dictionnaire.

Organisation du mémoire

Le chapitre 1 pose le cadre : notes MIMIC, SNOMED CT, split 240/32 et les deux métriques (mIoU caractère, rappel mention).

Le chapitre 2 replace Q1 et Q2 par rapport à JAMIA 2025 et à la classification sélective.

Le chapitre 3 décrit les deux pipelines tels qu’ils ont été reproduits.

Le chapitre 4 formalise l’alignement, l’oracle, les régimes et la file.

Le chapitre 5 présente les résultats empiriques.

Le chapitre 6 décrit les interfaces Streamlit, distinctes du protocole d’alignement.

Le chapitre 7 rassemble les apports, les limites et les perspectives.

Chapitre 1

Cadre institutionnel, données et métriques

1.1 Notes cliniques et EDS

Un entrepôt de données de santé agrège ce qui est structuré (actes, diagnostics CIM, biologie) et ce qui ne l'est pas (texte). Beaucoup de constats, de procédures, de localisations anatomiques n'existent que dans la phrase du clinicien. Tant qu'ils n'ont pas d'identifiant, ils n'entrent pas dans une cohorte reproductible.

On ne traite pas du NLP en général, mais du chaînon notes → mentions → SCTID, dans un régime où :

- le vocabulaire est **ouvert** (des centaines de milliers de concepts SNOMED, dont une petite fraction apparaît dans le train) ;
- la **longue traîne** domine : beaucoup de concepts n'ont qu'une occurrence ;
- le rédacteur abrège, suppose, mélange anglais technique et ellipse (`npo`, `lap chole`, `MI`) ;
- la granularité de SNOMED offre plusieurs codes « presque vrais » pour la même surface ;
- les frontières de spans sont instables d'un annotateur à l'autre.

On n'évalue pas la négation, la temporalité, ni la post-coordination (pas de NegEx [1] comme objet, pas d'assemblage « fracture + côté gauche » en expression composée). Le challenge a restreint le problème ; nous héritons de cette restriction.

1.2 SNOMED CT, en ce qu'il sert ici

SNOMED CT (*Systematized Nomenclature of Medicine — Clinical Terms*) est une terminologie clinique polyhiérarchique [10]. Un concept a :

- un identifiant stable (SCTID, entier) ;
- un Fully Specified Name et des synonymes ;
- des relations (`is-a`, finding site, method, etc.).

Ce n'est pas une liste plate de synonymes. Deux libellés proches peuvent pointer des concepts distincts ; deux libellés éloignés peuvent être des synonymes du même concept.

Un dictionnaire qui matche la surface joue sur les descriptions. Un encodeur qui plonge mention et libellés dans un même espace (SapBERT) joue sur une géométrie apprise sur UMLS [8]. Ni l’un ni l’autre n’épuise la sémantique des relations.

Le challenge n’utilise que trois sous-arbres :

$$Findings \quad / \quad Procedures \quad / \quad Body \ structure.$$

Environ 200 000 identifiants uniques dans ces branches pour le stage 2 de SnoBERT. Les médicaments à l’admission, le service, la date de naissance, sont hors périmètre — et explicitement ignorés par les pipelines (listes d’en-têtes à ne pas annoter).

1.3 MIMIC-IV-Note et le jeu du challenge

Les notes viennent de MIMIC-IV-Note [7], comptes rendus de sortie d’un hôpital américain, dé-identifiés. Le jeu annoté du challenge [6] fournit, pour un sous-ensemble de notes, des quadruplets (`note_id`, `start`, `end`, `concept_id`) produits par des professionnels de santé. C’est le format officiel des CSV d’annotation et de soumission DrivenData : une ligne par mention, avec l’identifiant de la note, les offsets de caractères du span, et le SCTID.

Chiffres du papier JAMIA, rappelés pour ancrer l’échelle :

TAB. 1.1 : Échelle du challenge SNOMED CT Entity Linking [3].

Quantité	Valeur
Notes annotées	272
Annotations	74 808
Concepts distincts	6 624
IAA (Jaccard)	$\approx 0,85$

Notre split de travail, hérité des expériences SnoBERT déjà menées sur la machine :

TAB. 1.2 : Split utilisé dans ce mémoire (notes cutmed, graine 42).

Partition	Notes	Mentions gold
Train / validation (4 folds)	240	66 775
Hold-out test	32	8 599

Ces 32 notes ne sont pas 8 599 tirages i.i.d. L’unité d’échantillonnage pertinente pour un intervalle de confiance est la **note**. Nous n’avons pas produit d’intervalle bootstrap sur 32 notes ; c’est une limite (chapitre 7).

1.4 La métrique du challenge, et celle que nous ajoutons

1.4.1 mIoU caractère, macro par concept

Le score officiel est une moyenne, *sur les concepts*, de l’IoU caractère entre l’ensemble des caractères assignés à ce concept dans la prédiction et dans le gold [3]. Conséquences :

- un concept rare pèse autant qu’un concept fréquent (macro) ;
- un span trop court ou trop long est puni même si le code est le bon ;
- un faux positif (code émis sur un passage non annoté) coûte ;
- un faux négatif (mention gold sans ticket) coûte.

C’est une métrique de *qualité d’annotation globale par concept*, pas un rappel de mentions. Le plafond humain $\approx 0,85$ rappelle qu’on ne « gagnera » pas 1,0.

1.4.2 Rappel mention

Nous ajoutons une métrique plus proche de la question « cette occurrence a-t-elle été sauvée ? ». Une mention gold est un *hit* si un ticket prédit chevauche le span avec un IoU $\geq 0,5$ *et* porte le bon SCTID. Le rappel mention est la moyenne de ces hits sur les 8 599 gold.

C’est cette métrique que nous jugeons honnête pour commenter l’oracle : l’oracle, par construction, n’émet que des vrais positifs (il jette les tickets faux). Son mIoU caractère explose en partie parce que les faux positifs de dictionnaire disparaissent. Le rappel mention, lui, reste une fraction de mentions gold correctement liées.

1.5 Deux pipelines, un même format de sortie

Quel que soit le système, la sortie d’inférence est un tableau :

(note_id, start, end, concept_id)

C’est le format du challenge. C’est aussi le format de l’alignement. Tout le reste — régimes, file, oracle — se calcule après coup, en comparant ces tickets au gold (laboratoire) ou entre eux (production).

1.6 Ce que « reproduction » veut dire ici

Reproduire KIRIs et SnoBERT n’est pas les réécrire. C’est :

- pour SnoBERT : partir des checkpoints NER déjà entraînés, lancer l’inférence hold-out, obtenir `submission_baseline.csv` (mIoU 0,4903 sur *ce* split, distinct du leaderboard privé 0,4194 : autre partition, autre post-traitement éventuellement) ;
- pour KIRIs : reconstruire la table (*header, mention*) sur le train cutmed, inférer par n-grammes et suppression de chevauchements, sans OMOP.

L’écart entre 0,49 (notre hold-out SnoBERT) et 0,42 (privé challenge) n’est pas un « nous avons battu le papier ». Ce sont des protocoles incomparables en l’état. Nous comparons *D* et *S* sur le même hold-out, c’est tout ce qui est licite.

1.7 Contraintes matérielles et choix qu’elles imposent

Le dictionnaire s’infère sur CPU. SnoBERT Stage 1 a été entraîné sur GPU (A100 / A10 selon les runs). Les poids NER / SapBERT d’un rerun « SnoBERT sans dictionnaire » ne sont pas tous disponibles comme ablation propre : l’option B du chapitre 5 n’est **pas** le pipeline deux étages sans `choose_concepts` ; c’est le résidu de surfaces hors vocabulaire du dictionnaire statique. C’est une limite, pas un second protocole.

1.8 Anatomie d’une note de sortie MIMIC

Une note de sortie MIMIC n’est pas un paragraphe libre. C’est un document semi-structuré, avec des en-têtes récurrents (histoire de la maladie actuelle, examen physique, imagerie, laboratoire, hospital course, plan). KIRIs exploite ces en-têtes comme clé. SnoBERT les utilise surtout négativement : certaines sections (médicaments à l’admission, à la sortie) sont exclues de l’annotation et du train.

Cette anatomie a trois conséquences pour l’évaluation.

Premièrement, une même surface change de sens selon la section. MI dans un en-tête cardiologique n’est pas MI dans un contexte valvulaire. Un dictionnaire sectionné encode ce fait ; un retriever qui ne voit que la mention doit le réapprendre par le voisinage de tokens, s’il le voit.

Deuxièmement, les offsets (*start, end*) sont des indices de caractères dans le texte brut, y compris espaces et retours à la ligne. Un décalage d’un caractère (balise HTML, normalisation) suffit à casser un span. L’équipe SNOBERT a corrigé manuellement une dizaine de notes pour cette raison. Nous héritons des fichiers cutmed déjà nettoyés ; nous n’avons pas refait l’audit d’offsets.

Troisièmement, une note longue concentre des dizaines de mentions. Les 8 599 gold ne sont pas 8 599 tirages : ce sont 32 documents. Toute statistique qui traite la mention comme unité i.i.d. surévalue la précision. Le chapitre 7 y revient.

1.9 Les trois branches SNOMED du challenge

Le challenge n'ouvre pas tout SNOMED CT. Il restreint les cibles à :

Findings

constatations cliniques, symptômes, diagnostics au sens large (hypertension, fièvre, épanchement).

Procedures

actes (cholécystectomie, intubation, dialyse).

Body structure

sites anatomiques (lobe inférieur gauche, valve mitrale).

Cette restriction n'est pas anodine. Elle écarte les médicaments, les organismes, les situations sociales, une grande partie des qualifieurs. Elle évite aussi, par construction, une partie de la post-coordination (pas besoin d'assembler « procédure + site » si le site est une mention à part). Le NER de SnoBERT a exactement ces trois étiquettes plus le vide. Un système qui « inventerait » un code médicament serait hors jeu — et hors gold.

Pour un EDS français, le transfert n'est pas immédiat : les notes sont en anglais américain, la terminologie cible n'est pas la CIM-10, et les en-têtes MIMIC ne sont pas ceux d'un dossier patient français. Ce mémoire ne prétend pas livrer un codeur SNOMED pour la France. Il livre un protocole de *comparaison de deux pipelines* sur un gold public.

1.10 Granularité, polysémie, abréviations

Trois phénomènes reviennent dans JAMIA et dans nos régimes.

Granularité. SNOMED offre souvent un concept générique et un concept spécifique (insuffisance rénale / insuffisance rénale aiguë; poumon / lobe inférieur gauche). Un annotateur choisit un niveau; un linker en choisit un autre; l'IoU caractère peut rester élevée si les spans se recouvrent, ou s'effondrer si l'un des deux n'annote pas le modificateur. Au grain mention, un hit exige le *même* SCTID : nous sommes plus sévères que « presque vrai ».

Polysémie. La même surface (**stable**, **MI**, **discharge**) reçoit plusieurs codes selon le contexte. JAMIA parle d'entropie d'annotation au niveau concept. C'est aussi là que se forment les ACCORD faux : les deux systèmes ont appris la même association majoritaire, fausse ici.

Abréviations. **npo**, **lap chole**, **cad**. La solution de KIRIs les range dans une table; notre reproduction, non. SnoBERT peut les retrouver si le NER segmente et si SapBERT a vu un libellé proche. D'où des S-SEUL justes, attendus.

1.11 Synthèse du chapitre

Le cadre est donc un gold public anglais, trois branches SNOMED, un split 240/32, et deux métriques qu'il ne faut pas confondre. La suite du mémoire compare D et S exclusivement sur ce hold-out.

Chapitre 2

Revue de la littérature et positionnement

On ne dresse pas un état du NLP biomédical. On replace Q1 et Q2 par rapport à ce qui est déjà mesuré sur *ce* jeu : le challenge DrivenData et l'article JAMIA qui le synthétise [3].

2.1 Deux pipelines, un même gold

Le linking clinique, ici, c'est trouver un span dans une note MIMIC et lui donner un SCTID parmi les trois branches du challenge (findings, procedures, body structure) [7, 6]. Les difficultés utiles ici sont connues : mention courte, en-tête de section comme seul contexte local, abréviations, polysémie, et un IoU caractère qui punit autant un span trop court qu'un mauvais code.

Deux solutions publiées sont alignées.

KIRIs [11] construit un dictionnaire : à une paire (en-tête, mention), on associe un identifiant, enrichi par OMOP, des abréviations et des règles. L'inférence est déterministe, sur CPU. Quand la surface n'est pas dans la table, le système se tait. Quand elle y est avec le mauvais code majoritaire, il se trompe sans le dire.

SnoBERT [13] enchaîne un NER BiomedBERT, un retrieval SapBERT [8], puis un dictionnaire statique (surface $\mapsto$ concept le plus fréquent en train) avec un seuil à 0,90. SapBERT place mentions et libellés SNOMED dans le même espace ; le code est un plus proche voisin cosinus. Le NER voit le contexte de la phrase ; SapBERT, souvent, voit surtout la mention. SnoBERT est déjà un hybride : ce n'est pas « le neural pur » face à « le dictionnaire ».

MITEL-UNIUD, troisième du challenge, passe par un LLM [12]. JAMIA le situe plus bas en mIoU, plus cher. Il n'est pas aligné ici. Il rappelle seulement qu'une troisième voie existait, et que le vote JAMIA l'incluait.

2.2 Ce que JAMIA a déjà établi

Davidson et al. [3] sont le point d'appui. On ne refait pas leur tableau de classement.

Les faits retenus : IAA Jaccard $\approx 0,85$, plafond humain du mIoU du challenge ; KIRIs 0,4202 et SNOBERT 0,4194 en privé, intervalles à 95 % qui se recouvrent ; Spearman des IoU par concept autour de 0,75 ; vote majoritaire des trois vainqueurs +0,022 seulement. Sur les concepts absents du train, le dictionnaire gagne même (0,270 contre 0,235). Les concepts difficiles pèchent surtout par le rappel (span manqué ou mauvais code). L'entropie d'annotation — plusieurs SCTID pour la même surface, **stable** par exemple

— pèse dans la difficulté.

Au niveau du *concept*, fusionner les vainqueurs rapporte donc très peu, et les deux premiers sont indiscernables.

Ce que JAMIA n’a pas mesuré :

1. travailler au grain de la **mention**, pas du concept. Une corrélation 0,75 entre concepts n’interdit pas que, sur une occurrence, KIRIs sauve une forme et SnoBERT une autre ;
2. distinguer le vote (toujours fusionner) de l’abstention (savoir quand ne pas faire confiance) ;
3. chercher un signal *sans gold* : en production, personne ne dit qui a raison ;
4. décrire les conflits par la distance d’édition des libellés FSN, sans en faire un linker.

Les trois premiers points sont Q1 (borne oracle, laboratoire) et Q2 (file, sans vérité terrain). Le quatrième est un contrôle, rapporté au chapitre 5.

2.3 Hybride d’architecture et hybride de décision

Combiner un dictionnaire et un encodeur n’est pas nouveau : SnoBERT le fait déjà dans son post-traitement, et JAMIA le fait par un vote. Ce que ces hybrides ne font pas, c’est *s’abstenir*. Le dict interne de SnoBERT écrase SapBERT au-dessus d’un seuil 0,90 ; le vote JAMIA prend toujours une voix majoritaire. Ni l’un ni l’autre ne produit une file.

La question n’est donc pas « comment mieux combiner ». C’est : le désaccord, lu sur les sorties, suffit-il à dire ce qu’un humain doit relire ?

2.4 Cadre : classification sélective et borne oracle

La file se lit dans le langage de la classification sélective. Chow [2] refuse d’émettre quand le risque est trop haut. Geifman et El-Yaniv [5] mesurent une courbe risque–couverture : quelle erreur reste-t-il sur la fraction qu’on garde ? Ici, par choix, on n’ôte pas de tickets, afin de ne pas perdre de rappel : on émet l’union, et l’on réserve la relecture au non-accord. La « couverture auto-validée », ce sont les accords. Les régimes n’ont pas été empilés un par un pour tracer la courbe ; c’est une limite, reprise au chapitre 7.

L’oracle de Q1 n’est pas une méthode. C’est le plafond d’un sélecteur qui verrait le gold et, à chaque mention, garderait le ticket juste s’il existe. Ce n’est pas un vote : un vote fusionne toujours ; l’oracle ne garde un ticket que s’il est juste.

2.5 Positionnement

JAMIA établit qu'au niveau du concept, KIRIs et SNOBERT sont indiscernables et qu'un vote n'apporte que +0,02. On déplace la question au niveau de la mention : le régime de désaccord, observable sans gold, permet-il une file dont le risque est supérieur à celui de l'accord ? Ce n'est pas un nouveau linker, et ce n'est pas la preuve qu'un hybride automatique est meilleur.

2.6 Synthèse du chapitre

La littérature utile se concentre sur JAMIA 2025 et sur la classification sélective. Ce qui manque (grain mention, abstention, signal sans gold) correspond à Q1 et Q2.

Chapitre 3

Reproduction des deux pipelines

Ce chapitre décrit les deux instruments tels qu'ils ont été reproduits, et non tels qu'ils ont été conçus. L'objectif n'est pas de réécrire KIRIs ou SnoBERT, mais de figer les hypothèses d'inférence qui alimentent l'alignement du chapitre 4.

3.1 Dictionnaire : principe

Un dictionnaire de linking ne « comprend » pas la phrase. Il mémorise des associations vues (ou construites) entre une *clé* et un concept, puis les rejoue. La clé peut être la surface seule (*hypertension* $\mapsto$ 38341003) ou une paire plus riche : *dans quelle section* la surface apparaît.

KIRIs a gagné le challenge avec cette idée, poussée loin : OMOP, abréviations, permutations de multi-mots, deux dictionnaires (casse / sans casse), résolution de chevauchements (plus long, plus spécifique de section), post-traitement par relations SNOMED [11]. Entraînement en minutes sur CPU ; inférence de l'ordre de quelques notes par minute sur une machine de bureau.

Ce chapitre décrit (i) la solution publiée, (ii) ce que nous avons réellement inféré, (iii) pourquoi l'écart entre les deux doit rester visible dans toutes les tables.

3.2 La solution KIRIs publiée

Le dépôt `dictmethod` construit, hors-ligne, des tables à partir :

- des annotations d'entraînement ;
- des libellés SNOMED CT du snapshot challenge ;
- des synonymes OMOP (Athena) ;
- d'une liste d'abréviations médicales publiques ;
- de règles (permutations, extensions).

À l'inférence, chaque note est découpée en sections (en-têtes MIMIC : *history of present illness*, *physical exam*, etc.). Dans chaque section, on cherche les mentions par n-grammes. Un match (*header*, *mention*) l'emporte sur un match (*any*, *mention*). Les chevauchements se résolvent en privilégiant les spans longs. Un post-traitement peut étendre ou spécialiser d'après les relations.

C'est un système **déterministe** une fois les tables figées. Pas de softmax, pas de seuil de cosinus. L'erreur typique n'est pas « le voisin dans l'espace latent » : c'est une clé absente, une clé ambiguë (vote majoritaire sur une surface polysémique), un en-tête mal détecté, un chevauchement mal tranché.

3.3 Ce que nous avons réellement inféré

Nous n'avons pas `kiri_dicts.pkl` ni les fichiers OMOP / abréviations dans l'environnement d'évaluation. Reconstruire la solution complète de KIRIs n'était pas possible dans le calendrier du mémoire.

Le module `oracle_study.kiri` implémente donc une **reproduction partielle** :

1. Sur le train seulement, pour chaque mention gold, extraire le texte normalisé et l'en-tête de section (code `mimic_common` de KIRIs : `get_sections`, `get_header_by_pos`).
2. Compter les SCTID par clé (*header, mention*) et par clé de repli (*any, mention*).
3. Garder le concept majoritaire. Pour la clé *any*, exiger une majorité stricte ($\geq 50\%$) afin de ne pas figer une polysémie non sectionnée.
4. À l'inférence : n-grammes sur tokens alphanumériques, lookup section puis *any*, `remove_overlaps`, ignorer certains en-têtes (médicaments, service, date de naissance), sauter un préfixe de note.

C'est le même matching que KIRIs, amputé. Ce n'est pas le vainqueur. Le mIoU obtenu sur le hold-out est 0,386 (rappel mention 0,757), clairement sous le 0,420 privé du challenge — ce qui est attendu : pas d'OMOP, pas d'abréviations, pas du post-traitement relationnel complet.

Dans tout le manuscrit, « KIRIs » dans une table désigne cette reproduction, sauf mention contraire.

3.4 Le dictionnaire statique de SnoBERT, à ne pas confondre

SnoBERT embarque déjà un dictionnaire (`most_common_concept.pkl`) : une surface normalisée (casse, ponctuation) est associée au concept le plus fréquent en train, *sans* en-tête de section [13]. Le post-traitement `choose_concepts` peut écraser le code SapBERT par ce lookup, avec un seuil de similarité 0,90 et une petite prime si le concept SapBERT a été vu en train.

Ce dictionnaire-là n'est pas KIRIs. Il n'a pas la clé de section. Il est un étage de SnoBERT, pas l'adversaire *D* de nos tables principales. L'option B (chapitre 5) s'en sert seulement pour définir un *résidu* : spans SnoBERT dont la surface n'est pas dans ce vocabulaire.

3.5 Propriétés du dictionnaire reproduit

Déterminisme, auditabilité (on peut imprimer la clé), coût CPU. Robustesse sur les formes vues, y compris — JAMIA le montre — sur certains concepts absents du train mais recouvrables par synonymes, dans la version OMOP, pas dans la nôtre. L'en-tête sert de contexte pauvre : MI n'a pas le même sens partout.

Toute surface nouvelle est un trou. Toute surface vue avec le mauvais code majoritaire est une erreur *confiante* : le système n'a pas de score d'incertitude autre que « pas de clé ». Les abréviations hors table et les permutations non générées sont perdues.

3.6 Algorithme d'inférence, pas à pas

On résume `oracle_study.kiri.predict_kiri` sans recopier le code.

1. Normaliser la note en minuscules. Repérer les en-têtes de la liste KIRIs (`common_headers`).
2. Tokeniser en spans alphanumériques. Pour chaque position de départ, construire les n -grammes jusqu'à la longueur maximale des clés.
3. Ignorer un préfixe de note (`skip_prefix=100`) et les sections médicaments / service / date de naissance.
4. Chercher d'abord (*header, mention*) ; à défaut, (*any, mention*).
5. Collecter tous les hits, puis `remove_overlaps` : on privilégie les mentions longues et les clés de section.

Il n'y a pas de score. Un hit existe ou n'existe pas. Le dictionnaire ne peut pas s'abstenir autrement qu'en se taisant.

3.7 Construction de la table sur le train

Pour chaque mention gold du train, on reconstitue la surface et l'en-tête. On incrémente un compteur SCTID par clé. Le concept retenu est le mode. La clé *any* n'est gardée que si le mode représente au moins la moitié des occurrences : une surface trop disputée sans section ne devient pas une règle globale. C'est une primitive d'entropie d'annotation, locale, sans modèle.

Cette table n'est pas OMOP. Elle ne connaît que ce que le train a annoté. Un synonyme SNOMED jamais vu en note n'existe pas pour D , alors qu'il existerait pour la solution complète de KIRIs et pour SapBERT (qui embedde les libellés).

3.8 Coût et auditabilité

L'inférence tient sur CPU. On peut, pour n'importe quel ticket, imprimer la clé qui l'a produit. Dans un EDS, un clinicien qui conteste un code peut voir « cette section, cette surface, ce vote majoritaire ». SnoBERT, à l'inverse, oppose un voisin cosinus dans un espace de 768 dimensions. Un conflit oppose souvent une clé à un voisin, pas seulement deux codes.

3.9 SnoBERT : NER, retrieval et post-traitement

SnoBERT, 2^e du challenge [13], est un pipeline à **deux étages**, déjà hybride à l'arrivée :

note $\rightarrow$ NER BiomedBERT (find / proc / body) $\rightarrow$ SapBERT k -NN $\rightarrow$ dict
statique + seuil $\rightarrow$ tickets

S contient déjà un dictionnaire ; D en est un autre, sectionné (KIRIs sans OMOP). La comparaison porte sur deux pipelines de production. Ce n'est pas une ablation du stage 2.




FIG. 3.1 : Pipeline SnoBERT tel qu'inféré.

3.10 Stage 1 — reconnaissance d'entités

Tâche : étiquetage de tokens en sept classes BIO (B/I-find, B/I-proc, B/I-body, O). Encodeur : BiomedBERT-large (Microsoft), éventuellement précédé d'un MLM in-domain (gain rapporté $\approx 0,005$ par les auteurs ; nous n'avons pas reproduit ce pré-entraînement).

Découpage : 4 folds sur notes. La soumission challenge est un ensemble de six modèles (poids de classes et nombres d'epochs variés). Dans nos runs hold-out, l'ensemble stage 1 est le meilleur checkpoint par fold selon le mIoU token de validation (quatre folds, moyenne $\approx 0,75$ en baseline).

Prétraitement notable : exclusion des sections médicaments à l'admission / à la sortie, correction manuelle d'une dizaine de notes (décalages d'offsets liés aux balises HTML), de l'ordre de 0,002 de score selon les auteurs.

Le NER ne produit pas de SCTID. Il produit des spans typés. Toute la sémantique fine (quel finding, quelle procédure) est renvoyée au stage 2.

3.11 Stage 2 — linking par proximité de libellés

Pour chaque concept des trois sous-arbres, on moyenne les embeddings SapBERT [8] de ses synonymes. Chaque span NER est encodé de la même façon. Le concept prédit est le plus proche en cosinus.

C'est un retriever, pas un classifieur à 200 000 logits. L'erreur typique est le voisin distributionnel : synonyme acceptable, ou cousin morphologique, ou concept trop générique / trop spécifique.

Un contrôle que nous avons repris (spans gold, pas NER) : Sim@1 / Sim@5 par branche, après exclusion d'un concept Findings dont l'embedding était NaN (289306008) :

TAB. 3.1 : Qualité du retrieval SapBERT seul (spans gold).

Branche	Sim@1	Sim@5
Body structure	0,738	0,811
Findings	0,624	0,748
Procedure	0,490	0,706

Le linking n'est pas « résolu » une fois le span trouvé, surtout en procédures. SapBERT encode la mention, pas l'en-tête comme clé. Le seuil 0,90 n'est pas une courbe risque-couverture. L'hypothèse d'une classe d'erreurs faite de contraires morphologiques (hypertension / hypotension) est mesurée au chapitre 5 : elle y est presque vide.

3.12 Post-traitement : le dictionnaire déjà dans S

`choose_concepts` [13] :

- construit un dictionnaire $\text{surface} \mapsto \text{concept}$ majoritaire du train ;
- relit chaque span ; si la surface est dans le dict, peut remplacer SapBERT ;
- applique un seuil 0,90 sur le score SapBERT (avec une prime +0,05 si le concept SapBERT appartient au train) ;
- filtre une blacklist de mots outils.

Conséquence pour l'interprétation : un accord KIRIs / SnoBERT n'est pas « le symbolique et le dense disent la même chose ». C'est parfois « deux dictionnaires, l'un sectionné et l'autre non, plus un retriever, convergent ». Nous ne démêlons pas, dans les tables A, la part du dict interne de SnoBERT. L'option B esquisse le résidu OOV, sans prétendre être l'ablation propre.

3.13 Score hold-out utilisé ensuite

Sur les 32 notes, SnoBERT complet obtient un mIoU caractère de 0,4903 et un rappel mention de 0,768. C'est le S de toutes les tables A. Ce n'est pas le 0,4194 du leaderboard privé.

3.14 Ensembling du stage 1

Les auteurs du challenge entraînent plusieurs NER (folds, poids de classes, durées). L'inférence moyenne ou vote les logits. Dans nos runs, nous prenons le meilleur checkpoint de validation par fold et nous les combinons par ensemble pour le hold-out. Le mIoU token de validation tourne autour de 0,75 : le NER « voit » une grande partie des entités, mais voir un span n'est pas le lier. L'écart entre 0,75 token et 0,49 EL mesure le coût du stage 2, plus les frontières de caractères.

3.15 Pourquoi SnoBERT n'est pas « le neural pur »

Trois composants non neuronaux, déjà dans S :

1. règles d'exclusion de sections ;
2. dictionnaire `most_common_concept` ;
3. seuil 0,90 et blacklist de mots outils.

La comparaison n'oppose pas « un Transformer » et « un dictionnaire » : S est déjà un pipeline hybride, D un autre dictionnaire. La complémentarité mesurée au chapitre 5 est donc une complémentarité de pipelines, utile pour un EDS, sans constituer une ablation du dense et du symbolique.

3.16 Synthèse du chapitre

Deux pipelines de production, déjà publiés, sont donc disponibles sur le même hold-out : un dictionnaire sectionné, reproduit de façon partielle, et SnoBERT complet, déjà hybride. La suite du mémoire ne les combine pas en un troisième linker. Elle compare leurs tickets mention à mention.

Chapitre 4

Méthodologie : alignement, oracle et file de relecture

4.1 But

On ne remplace pas KIRIs ni SnoBERT. On répond à deux questions chiffrées, sur le même hold-out, avec des définitions figées : (i) le plafond de complémentarité d'un dictionnaire sectionné et d'un pipeline dense déjà hybride (oracle) ; (ii) l'efficacité d'une file de relecture qui n'utilise que le régime observable, donc utilisable sans vérité terrain.

Le code est dans `oracle_study/` : alignement, régimes, oracle, file, tests d'invariants.

4.2 Alignement mention à mention

Soit G l'ensemble des mentions gold d'une note. Soit P_D et P_S les tickets prédits.

Pour chaque $g \in G$, on retient le ticket de P_D (resp. P_S) de même `note_id` qui maximise l'IoU de span, s'il est $\geq 0,5$; sinon, pas de match.

$$\text{IoU}([a, b), [c, d)) = \frac{|[a, b) \cap [c, d)|}{|[a, b) \cup [c, d)|}.$$

Un *hit* dictionnaire : match D et `concept_idD` = `concept_idg`. Idem S . Un hit oracle : hit D ou hit S .

Le seuil 0,5 est une convention de matching, pas la métrique du challenge. Le mIoU caractère se calcule à part, sur les soumissions complètes, avec la fonction `iou_per_class` du dépôt SnoBERT.

4.3 Cinq régimes

Le régime d'une mention gold ne dépend *pas* du gold pour être *nommé* à l'inférence, sauf AUCUN qui, dans notre table, est « ni match D ni match S » relativement aux gold — en production, les mentions gold invisibles n'apparaissent tout simplement pas. Les quatre autres se lisent sur les tickets.



FIG. 4.1 : Les cinq régimes. Seul l'ACCORD sort de la file de relecture.

Définition opérationnelle (`mention_regime`) :

- match D et match S et même SCTID $\rightarrow$ ACCORD ;

- match D et match S et SCTID différents $\rightarrow$ CONFLIT ;
- match D seulement $\rightarrow$ D-SEUL ;
- match S seulement $\rightarrow$ S-SEUL ;
- aucun match $\rightarrow$ AUCUN.

« Erreur » dans les tables de file : la mention n'est un hit pour *aucun* des deux (complémentaire du hit oracle). Un CONFLIT peut donc être *non-erreur* : l'un des deux a le bon code. Un ACCORD peut être une erreur : les deux ont le même mauvais code.

4.4 Oracle : un plafond, pas une méthode

L'oracle, pour chaque gold, émet le ticket hit s'il existe ; en cas de double hit, il garde celui de meilleur IoU de span. S'il n'y a pas de hit, il n'émet rien pour cette mention.

Conséquences :

- l'oracle **voit le gold** : inutilisable en production ;
- son rappel mention est $\mathbb{P}(D \text{ hit ou } S \text{ hit})$;
- son mIoU caractère est un plafond *et* un biais : plus de FP de dictionnaire $\Rightarrow$ mIoU D tiré vers le bas ; l'oracle ne les émet pas, d'où un Δ mIoU trop large, en partie artificiel.

Le Δ que nous commentons pour un EDS est le Δ_{oracle} de **rappel mention** (Q1) :

$$\Delta_{\text{oracle}} = R_{\text{oracle}} - \max(R_D, R_S).$$

Invariant testé : $R_{\text{oracle}} \geq R_D$ et $R_{\text{oracle}} \geq R_S$ (à 10^{-12} près). Ce n'est pas un vote : un vote fusionne toujours ; l'oracle ne garde un ticket que s'il est juste.

4.5 File de relecture sans gold

Politique, une fois choisie, tenue jusqu'au bout :

Émettre $D \cup S$. **Relire** tout régime sauf ACCORD.

Pourquoi émettre ? Un EDS qui jette les unilatéraux jette aussi les mentions qu'un seul système a justes (effectifs au chapitre 5). On garde le rappel, on relit ensuite.

Pourquoi relire le non-accord ? C'est le seul signal disponible sans gold, sans calibration de SapBERT et sans troisième réseau.

Métriques de la file, toutes calculables *en laboratoire* (il faut le gold pour savoir ce qu'est une erreur) mais la *composition* de la file ne nécessite pas le gold :

$$\begin{aligned}
\text{taille} &= n_{\text{CONFLIT}} + n_{\text{D-SEUL}} + n_{\text{S-SEUL}} + n_{\text{AUCUN}}, \\
\text{rappel des erreurs} &= \frac{\text{erreurs dans la file}}{\text{erreurs totales}}, \\
\text{précision des erreurs} &= \frac{\text{erreurs dans la file}}{\text{taille de la file}}.
\end{aligned}$$

Le rappel des erreurs n'est pas le rappel mention. C'est : parmi les mentions que *personne* n'a correctement liées, quelle fraction apparaît dans la liste que l'humain ouvre.

4.6 Décomposition du rappel d'erreurs

Parmi les erreurs, AUCUN en est une **par construction** : pas de ticket $\Rightarrow$ pas de hit. Les mettre dans la file, c'est recenser des absences. Cela gonfle le rappel d'erreurs. La lecture honnête décompose ce rappel en silence (AUCUN) et en désaccord stricto sensu (CONFLIT + D-SEUL + S-SEUL). Les parts chiffrées figurent au chapitre 5.

C'est le désaccord stricto sensu que l'on peut présenter comme « les deux systèmes ne sont pas d'accord, ou un seul a parlé ». Les erreurs d'ACCORD sont le coût de la politique : faux amis, abréviations partagées, granularité. La file ne les verra jamais.

4.7 Option B (contrôle, pas un chapitre parallèle)

On filtre les tickets SnoBERT dont la surface est dans le dictionnaire statique interne, pour ne garder qu'un résidu « longue traîne ». Ce n'est pas SnoBERT sans `choose_concepts` : les poids d'un rerun NER+SapBERT sans dict ne sont pas sur disque. On en rapporte les tables en annexe et une phrase au chapitre 5.

4.8 Distance d'édition, descripteur et non linker

Pour chaque mention où D et S ont un match, on compare les Fully Specified Names des deux SCTID (minuscules, tag sémantique retiré). La distance de Levenshtein ainsi obtenue décrit le conflit ; elle ne produit pas de ticket. Un voisin proche est fixé *a priori* : édition ≤ 2 et libellé d'au moins six caractères, plus une liste fermée d'échanges de préfixe (hyper/hypo, left/right, acute/chronic, ...). Les effectifs sont au chapitre 5.

4.9 Ce que nous n'avons pas fait

Pas de courbe risque-couverture en empilant les régimes (ACCORD seulement, puis +S_SEUL, etc.). Pas de bootstrap sur notes. Pas de classifieur de régimes. Pas de Levenshtein comme linker, ni de cosinus SapBERT : la distance d'édition sert seulement

à décrire les FSN en conflit (chapitre 5). Pas de LLM. Ces absences sont des limites, listées au chapitre 7.

En classification sélective, on ne réduit pas le risque en taisant des tickets (on perdrait du rappel). On concentre l'attention humaine sur les cas non auto-validés. Le coût, jamais estimé en euros, est le temps annotateur $\times$ la taille de file, contre les erreurs laissées dans l'accord.

4.10 Invariants et tests

Le paquet `oracle_study.tests` fixe des invariants : l'oracle ne peut pas être plus mauvais que D ni que S ; les régimes partitionnent les mentions ; la file est exactement le complémentaire de l'ACCORD. Ce n'est pas un résultat : c'est un contrôle d'invariants, pour qu'un rappel d'erreurs ne vienne pas d'un joint mal fait.

4.11 Synthèse du chapitre

Pas de nouvel estimateur : un protocole de mesure, une borne, une politique, et une décomposition qui empêche de trop vendre cette politique.

Chapitre 5

Résultats empiriques

Sauf mention contraire, toutes les tables de ce chapitre sont l’**option A** : reproduction de KIRIs $\times$ SnoBERT complet. $n = 32$ notes, 8 599 mentions gold.

5.1 Scores globaux et borne oracle

TAB. 5.1 : Option A — scores globaux. L’oracle voit le gold.

Système	mIoU caractère	Rappel mention
KIRIs	0,3863	0,7572
SnoBERT complet	0,4903	0,7680
Oracle	0,7244	0,8509
Δ vs meilleur des deux	0,2340	0,0829

Lecture du rappel. SnoBERT est le meilleur système seul (0,768). L’oracle monte à 0,851 : $\Delta = +8,3$ points. Environ 15 % des mentions ($1 - 0,851$) ne sont sauvées par personne. H1 n’est pas rejetée : il existe une complémentarité mention que le vote JAMIA au grain concept n’avait pas mesurée.

Lecture du mIoU. Les +23 points ne sont pas le gain opérationnel d’un EDS. L’oracle n’émet que des VP. KIRIs produit des FP de lookup ; les écarter gonfle le mIoU. Le chiffre honnête du plafond opérationnel est le rappel, pas 0,72.

Complémentarité brute. 517 mentions justes seulement chez KIRIs, 554 seulement chez SnoBERT. Ce ne sont pas les mêmes erreurs. C’est le contenu du Δ de rappel.

5.2 Table des régimes

TAB. 5.2 : Option A — régimes. $P(\text{erreur}) = 1 - \mathbb{P}(\text{hit oracle})$.

Régime	n	%	$P(\text{err.})$	D seul juste	S seul juste	Les deux justes
ACCORD	6168	71,7	0,060	0	0	5798
CONFLIT	506	5,9	0,115	196	252	0
D-SEUL	743	8,6	0,304	517	0	0
S-SEUL	653	7,6	0,152	0	554	0
AUCUN	529	6,2	1,000	0	0	0

Commentaires.

- ACCORD : 72 % du volume, 6 % d'erreur. C'est le régime qu'on auto-valide. 5 798 mentions vraiment justes ; 370 accords faux.
- CONFLIT : rare (6 %), erreur 11,5 % — plus que l'accord, sans être un échec conjoint. Souvent *l'un des deux a raison* (196 vs 252). Le conflit n'est pas « les deux se trompent » ; c'est « il faut choisir ».
- D-SEUL : le plus risqué des régimes à ticket (30 % d'erreur), mais 517 sauvetages dictionnaire. Jeter *D* quand *S* se tait coûterait cher en rappel.
- S-SEUL : 15 % d'erreur, 554 sauvetages SnoBERT (longue traîne, abréviations hors table de *D*).
- AUCUN : 6,2 % des mentions, 100 % d'erreur. Silence.

H2 : $P(\text{erreur} \mid \text{non-accord})$ est un mélange. Le non-accord n'est pas homogène. D-SEUL et AUCUN tirent le risque vers le haut ; CONFLIT est plus proche de l'accord qu'on ne le croirait. Une file unique « tout sauf accord » est donc une politique *grossière*, défendable par simplicité, pas par optimalité.

5.3 Efficacité de la file

TAB. 5.3 : File de relecture (émettre l'union, relire le non-accord).

Quantité	Valeur
Mentions	8599
Erreurs (ni <i>D</i> ni <i>S</i> justes)	1282
Taille de la file	2431 (28,3 % des mentions)
Rappel des erreurs (file)	71,1 %
Précision des erreurs (file)	37,5 %
Erreurs restantes dans ACCORD	370 (28,9 % des erreurs)

TAB. 5.4 : Décomposition des 1 282 erreurs par régime.

Régime	File ?	n	Erreurs	Part des erreurs
ACCORD	non	6168	370	28,9 %
CONFLIT	oui	506	58	4,5 %
D-SEUL	oui	743	226	17,6 %
S-SEUL	oui	653	99	7,7 %
AUCUN	oui	529	529	41,3 %



FIG. 5.1 : Les 1 282 erreurs. La file voit les deux premiers blocs (71 %). Le troisième lui échappe.

On relit 28 % des mentions ; 71 % des erreurs s’y trouvent. Sur ces 71 points, 41 sont du silence et 30 du désaccord stricto sensu ($58 + 226 + 99 = 383$ erreurs, $383/1282 \approx 30 \%$). Les 370 accords faux restent hors file.

5.4 Exemples

Les lignes ci-dessous viennent de `exemples_A.csv` : surfaces lues dans la note hold-out, SCTID et FSN du gold et des tickets. Elles illustrent la définition des régimes, pas une revue clinique.

TAB. 5.5 : Exemples d’alignement (option A). FSN raccourcis (tag sémantique omis).

Surface	Régime	Gold		<i>D</i>	<i>S</i>
lactate	ACCORD	3926003	lactic acid meas.	idem	idem
pulmonary embolism	CONFLIT	59282003	pulmonary embolism	310039004 pulmonary medicine service	59282003 pulmonary embolism
Low limb lead voltage	D-SEUL	251147008	low QRS limb leads	idem	—
gastric AVMs	D-SEUL	717866008	AVM of stomach structure	69695003	—
dorsiflexion	S-SEUL	19876005	ankle dorsiflexion test	—	idem
lung	S-SEUL	94391008	metastasis to lung	—	39607008 lung structure
costovertebral angle tenderness	AUCUN	102830001	renal angle tenderness	—	—

Lire le CONFLIT : *D* a lié l’embolie à un *service*, *S* au trouble ; l’oracle prendrait *S* ; la file signale le doute. Lire le second D-SEUL : *D* a une clé, trop générique (estomac au lieu de la malformation) ; *S* se tait. Lire AUCUN : la mention gold n’a pas de ticket.

5.5 Voisinage morphologique des conflits

L’hypothèse, souvent associée aux embeddings [9], est que deux libellés presque identiques (hypertension / hypotension) se retrouvent voisins, et que le dictionnaire y serait plus sûr. Nous ne calculons pas de cosinus SapBERT. Nous mesurons seulement la distance d’édition de Levenshtein entre Fully Specified Names, tag sémantique retiré, minuscules. Un voisin proche est un couple de concepts distincts dont cette distance est ≤ 2 , avec un libellé d’au moins six caractères. Les libellés viennent du RF2 disponible dans l’environnement (snapshot 2026-02-01) ; les identifiants sont ceux du gold. Ce n’est pas un troisième linker.

TAB. 5.6 : Distance d'édition entre FSN de D et de S , mentions en CONFLIT ($n = 506$). Trois conflits n'ont pas de FSN S dans le snapshot.

FSN-Lev(D,S)	n	% des conflits
≤ 2	2	0,4
3–5	21	4,2
6–10	98	19,4
11–20	247	48,8
> 20	135	26,7
FSN S absent	3	0,6
Médiane (503 FSN joints)	16	—

Les deux mentions à distance 1 sont la même paire, deux fois, dans la même note : **petechiae**. D émet *Petechia (morphologic abnormality)*, S émet *Petechiae (disorder)*, qui est le gold. C'est une granularité SNOMED (morphologie vs trouble), pas un couple hyper / hypo. Sur ces deux lignes, S a raison ; une règle « si édition faible, émettre D » se tromperait.

Sur tout le hold-out, 7 mentions seulement satisfont le critère de voisin (édition ≤ 2 ou échange de préfixe **left/right**, etc.). Aucune n'est un échange hypertension / hypotension : les 10 mentions gold « hypotension » / « hypotensive » sont des ACCORD (FSN *Low blood pressure*), et les hypertensions vues sont des ACCORD également. La classe est trop petite pour porter une politique, et trop petite pour en faire un défaut de SapBERT.

La bande 3–5 (21 conflits) n'accumule pas davantage d'antonymes. Ce sont surtout des écarts de spécificité (*left pneumothorax* vs *pneumothorax*, *lesion* vs *skin lesion*).

TAB. 5.7 : Les motifs « morpho voisin » du hold-out (7 mentions, 5 paires).

Surface (n)	Régime	FSN D	FSN S	Juste
petechiae ($\times 2$)	CONFLIT	Petechia (morph. abn.)	Petechiae (disorder)	S
gluten free diet ($\times 2$)	S-SEUL	—	Gluten free diet (regime/therapy)	ni l'un ni l'autre
Trop I	D-SEUL	Troponin measurement	—	ni l'un ni l'autre
wrist	CONFLIT	left wrist region	Wrist structure	ni l'un ni l'autre
shoulder	CONFLIT	right shoulder region	Shoulder structure	ni l'un ni l'autre

Code : `python -m oracle_study.run_contraires`. Sorties : `oracle_study/output/contraires_A.csv`.

5.6 Option B, en une sous-section

Résidu neural : rappel 0,066, mIoU 0,137. Oracle rappel 0,815, Δ vs KIRIs +0,058. Les régimes s'effondrent vers D-SEUL (82,5 %) : presque tout le gold est couvert par le dictionnaire dès que SnoBERT OOV se tait. Ce n'est pas une comparaison équitable de deux étages. Table complète : annexe B.

5.7 Lecture

1. Il y a complémentarité mention (Δ rappel +8,3 points, 517 + 554 sauvetages exclusifs).
2. Une file de 28 % de volume capte 71 % des erreurs, *dont une majorité relative de silences*.
3. L'accord n'est pas la vérité (6 % d'erreur ; 29 % des erreurs totales).
4. On n'a pas montré qu'un vote, une cascade, ou un classifieur de régimes bat SnoBERT en mIoU sans gold.
5. Les conflits ne sont pas des contraires morphologiques : médiane d'édition 16 entre FSN, 2 mentions à distance ≤ 2 , et sur ces deux-là *S* a raison.

5.8 Lecture EDS des effectifs

Sur 8 599 mentions :

- 5 798 accords justes : on peut les coder sans humain, au prix des 370 accords faux (6 % de ce régime, 4,3 % de toutes les mentions).
- 1 071 mentions sauvées par un seul système (517 + 554) : les jeter pour « n'émettre que l'accord » ferait chuter le rappel. D'où la politique *émettre l'union*.
- 529 silences : aucun des deux n'a vu la mention. Seul un humain qui relit *toute* la note, ou un troisième détecteur, les rattrape. La file les contient en laboratoire parce que nous partons du gold ; l'écran de production, non.
- 58 conflits qui sont des erreurs (les deux faux) contre 448 conflits où l'un des deux a raison. Le conflit est surtout un *problème de choix*, pas un double échec.

5.9 Comparaison qualitative à un vote

Un vote mention, si on l'avait fait, n'aurait pas de voix majoritaire à deux systèmes : en CONFLIT, 1–1. Il faudrait une voix prépondérante (toujours D , toujours S , ou une règle). Toujours S ramène à SnoBERT. Toujours D ramène à KIRIs, plus faible en mIoU. Une règle « D si édition de $FSN \leq 2$ » ne s'applique qu'à deux mentions, où S est déjà juste (section 5.5). Nous n'avons donc **pas** de troisième ligne « hybride déployé » dans la table 5.1, et c'est volontaire.

5.10 Stabilité à $n = 32$ notes

Les ordres de grandeur (72 % d'accord, 6 % de silence, Δ rappel de quelques points, pas de 0,001) sont assez gros pour n'être probablement pas du bruit de trois notes aberrantes. Les décimales (0,115 vs 0,060) mériteraient un bootstrap. Nous publions les secondes avec les premières, sans parler de significativité statistique.

5.11 Synthèse du chapitre

H1 n'est pas rejetée : le Δ_{oracle} de rappel vaut +8,3 points. La file unique relit 28 % du volume et place l'annotateur devant 71 % des erreurs, dont 41 points de silence. Ces chiffres sont ceux du hold-out ; ils ne se confondent pas avec le F1 des interfaces Streamlit.

Chapitre 6

Application : interfaces Streamlit

6.1 Rôle de ce chapitre

Deux applications Streamlit montrent, note par note, la sortie de chaque linker. Elles ne calculent pas les tables du chapitre 5 : pas d'alignement D contre S , pas de régimes, pas d'oracle. Elles affichent les spans et un tableau de prédiction. Le code se trouve dans `snomedEL/demo_dict/` et `snomedEL/demo_snobert/`.

6.2 Deux modes

Mode live. On colle une note. Le dictionnaire (`demo_dict/app.py`) ou SnoBERT (`demo_snobert/app_sno_predict.py`) renvoie les mentions, un surlignage et un tableau (surface, SCTID, type, score). Sans gold, on ne sait pas si le code est juste. C'est la situation d'un EDS qui n'a que le texte.

Mode laboratoire. On choisit une note déjà annotée. L'écran compare la prédiction au gold : vert si le span coïncide, jaune si le système a ajouté un span absent du gold, rouge si une annotation n'a pas été proposée. Un tableau liste les ajouts et les manques. Des compteurs donnent précision, rappel et F1 sur cette note, ainsi qu'une agrégation sur le corpus chargé. Un curseur de score (confiance historique côté dictionnaire, cosinus SapBERT côté SnoBERT) filtre les tickets.

Pour SnoBERT, `app_snobert.py` lit `test_notes.csv` : les 32 notes du hold-out. Les fichiers `v1/v2` portent 240 notes ; ce n'est pas le split des tables. Pour le dictionnaire, `app6.py` compare sur les notes d'entraînement et, lorsque le fichier est présent, s'appuie sur `kiri_dicts.pkl`, donc pas forcément sur la reproduction partielle D des chapitres 3 et 5.

6.3 Captures (mode laboratoire)

Les figures 6.1 et 6.2 illustrent ce mode. Chaque application n'affiche qu'un système. Les pourcentages du bandeau ne sont pas le rappel mention ni le Δ_{oracle} du chapitre 5.





FIG. 6.1 : Interface SnoBERT (app_snobert.py), note 10989002-DS-3 du hold-out. Vert : span prédit qui chevauche le gold ; jaune : prédiction absente du gold ; rouge : annotation manquée. Le F1 affiché repose sur un matching d'offsets, distinct de l'IoU $\geq 0,5$ et de l'égalité des SCTID.



D.

6.6 Synthèse du chapitre

Les interfaces rendent visible, note par note, ce que les tables agrègent. Elles n'implémentent pas la file *D* contre *S*. Pour la soutenance, l'écran de référence est `app_snobert.py` sur les 32 notes du hold-out.

Chapitre 7

Conclusion et perspectives

7.1 Synthèse des apports

7.1.1 Apports méthodologiques

Le mémoire traite KIRIs et SnoBERT comme des instruments déjà disponibles, et non comme des inventions. Il propose un protocole d’alignement au niveau mention (IoU de $\text{span} \geq 0,5$ et égalité de SCTID), cinq régimes qui partitionnent le hold-out, une borne oracle qui n’est pas une méthode déployable, et une file de relecture dont la composition ne requiert pas la vérité terrain.

7.1.2 Apports empiriques

Sur 32 notes et 8 599 mentions, les erreurs des deux pipelines ne tombent pas toujours au même endroit. Un sélecteur qui verrait le gold gagnerait huit points de rappel ; quinze pour cent des mentions resteraient hors d’atteinte. Ce sélecteur disparaît une fois le gold retiré. Ce qui reste observable, c’est l’accord. En faisant confiance aux accords et en mettant le reste en file, on relit 28 % des occurrences et l’on y trouve 71 % des échecs conjoints. Ce 71 % est en bonne partie du silence, et près de 30 % des échecs — les accords trompeurs — n’apparaissent jamais dans la liste.

Le mémoire n’a pas montré qu’un hybride automatique est meilleur. Il a mesuré ce qu’un choix parfait pourrait gagner, et ce qu’une file attrape lorsqu’elle se contente de signaler le doute. Ce résultat est étroit et reproductible à partir de `oracle_study`.

7.1.3 Positionnement par rapport à la littérature

Davidson et al. [3] ont voté au niveau du concept et obtenu +0,02. Ici, on ne vote pas. On mesure un plafond de choix par mention, puis une file. Les deux constats tiennent ensemble : toujours fusionner les vainqueurs, au concept, ne paie presque rien ; pouvoir choisir le bon ticket, à la mention, paierait huit points de rappel, à condition de savoir choisir. La file ne choisit pas ; elle montre les cas où il faudrait le faire, ou ceux où il n’y a rien.

Chez Geifman et El-Yaniv [5], on s’abstient d’émettre. Ici, afin de ne pas perdre de rappel, on émet l’union et l’on réserve seulement la confiance. La précision d’erreurs de la file est de 37,5 % : plus d’une mention sur deux dans la liste n’est pas une erreur au sens oracle. Relire, ce n’est donc pas seulement corriger ; c’est aussi confirmer.

7.2 Limites du travail

Les linkers ne sont pas de l’auteur : reproduction, et non conception. La reproduction de KIRIs n’est pas le 0,4202 du leaderboard. *S* est déjà hybride, de sorte que la comparaison n’est pas une ablation neurale. L’échantillon tient en 32 notes, sans intervalle bootstrap ; les 8 599 mentions sont corrélées intra-note. Les textes sont de l’anglais MIMIC, sans transfert vers le français hospitalier. L’IAA à 0,85 borne le mIoU du challenge, pas le rappel mention. L’option B n’est pas un SnoBERT sans dictionnaire. Sans gold, AUCUN n’apparaît pas : le mode live des démos ne montre que les tickets émis. Le mode laboratoire colorie les manques d’une système, et non le silence conjoint. Il n’y a ni courbe d’empilement des régimes, ni mesure de temps annotateur. Ni la post-coordination ni la négation ne font partie de la tâche. La distance d’édition entre FSN décrit les conflits ; elle n’est pas un score SapBERT, et la classe des voisins à édition ≤ 2 est trop petite (2 mentions) pour une règle d’arbitrage.

7.3 Perspectives

Empiler les régimes sur une courbe risque–couverture. Tirer un bootstrap sur les notes, comme JAMIA. Séparer tête et queue de concepts. Réaligner sur KIRIs complet si les fichiers OMOP deviennent disponibles. Un encodeur de plus ne répondrait ni à Q1 ni à Q2.

7.4 Conclusion finale

Q1 : il existe une complémentarité mention d’environ huit points de rappel, que le vote JAMIA au grain concept n’avait pas mesurée. Q2 : une file unique capte 71 % des erreurs en relisant 28 % du volume, mais 41 de ces 71 points sont du silence. L’objet du mémoire n’est donc pas un nouveau linker. C’est un protocole de mesure, une borne, et une politique d’attention humaine dont il faut lire la décomposition avant d’en tirer une règle d’exploitation.

Bibliographie

- [1] Wendy W. Chapman, Will Bridewell, Paul Hanbury, Gregory F. Cooper, and Bruce G. Buchanan. A simple algorithm for identifying negated findings and diseases in discharge summaries. *Journal of Biomedical Informatics*, 34(5) :301–310, 2001.
- [2] C. K. Chow. An optimum character recognition system using decision functions. *IRE Transactions on Electronic Computers*, EC-6(4) :247–254, 1957.
- [3] Rory Davidson, Will Hardman, Guy Amit, Yonatan Bilu, Vincenzo Della Mea, Aleksandr Galaida, Irena Girshovitz, Mikhail Kulyabin, Mihai Horia Popescu, Kevin Roitero, Gleb Sokolov, and Chen Yanover. SNOMED CT entity linking challenge. *Journal of the American Medical Informatics Association*, 32(9) :1397–1406, 2025.
- [4] DrivenData. SNOMED CT entity linking challenge. <https://www.drivendata.org/competitions/258/competition-snomed-ct>, 2024.
- [5] Yonatan Geifman and Ran El-Yaniv. Selective classification for deep neural networks. In *Advances in Neural Information Processing Systems*, 2017.
- [6] Will Hardman, Michael Banks, and Rory Davidson. SNOMED CT entity linking challenge dataset. PhysioNet, version 1.0.0, 2023.
- [7] Alistair E. W. Johnson, Tom J. Pollard, Steven Horng, Leo Anthony Celi, and Roger G. Mark. MIMIC-IV-Note : Deidentified free-text clinical notes. *PhysioNet*, 2023.
- [8] Fangyu Liu, Ehsan Shareghi, Zaiqiao Meng, Marco Basaldella, and Nigel Collier. Self-alignment pretraining for biomedical entity representations. In *Proceedings of NAACL*, 2021.
- [9] Nikola Mrkšić, Diarmuid Ó Séaghdha, Blaise Thomson, Milica Gašić, Lina Rojas-Barahona, Pei-Hao Su, David Vandyke, Tsung-Hsien Wen, and Steve Young. Counter-fitting word vectors to linguistic constraints. In *Proceedings of NAACL*, 2016.
- [10] SNOMED International. SNOMED CT international edition, 2023. Snapshot challenge 2023-05-31.
- [11] Team KIRIs. SNOMED CT entity linking challenge, 1st place solution. DrivenData / GitHub, licence MIT, 2024.
- [12] Team MITEL-UNIUD. SNOMED CT entity linking challenge, 3rd place solution. DrivenData / GitHub, licence MIT, 2024.

- [13] Team SNOBERT. SNOMED CT entity linking challenge, 2nd place solution. DrivenData / GitHub, licence MIT, 2024.

Annexe A

Protocole figé et formules

A.1 Décisions figées

- Split : `test_notes.csv` / `test_annotations.csv`, 32 notes, graine 42.
- *D* : reproduction de KIRIs, train cutmed, pas d'OMOP.
- *S* : `submission_baseline.csv`.
- Match : IoU de span $\geq 0,5$, un prédit par gold (meilleur IoU).
- Accord : même SCTID après match.
- Oracle : ticket hit, tie-break IoU de span ; pas de ticket si double miss.

A.2 Commandes

Depuis la racine du dépôt `snomedEL` :

```
python -m oracle_study.tests.test_oracle
python -m oracle_study.run_holdout --pair both
python -m oracle_study.run_review_queue
python -m oracle_study.tests.test_contraire
python -m oracle_study.run_contraire
```

Sorties : `oracle_study/output/align_A.csv`, `tables_memoire.md`, `table_file_relecture.md`, `exemples_A.csv`, `contraire_A.csv`, `contraire_tables.md`.

Annexe B

Option B (contrôle)

Dictionnaire = KIRIs (reproduction). Neural = spans SnoBERT hors vocabulaire du static dict. **Pas** un rerun sans `choose_concepts`.

TAB. B.1 : Option B — scores globaux.

Système	mIoU caractère	Rappel mention
KIRIs	0,3863	0,7572
SnoBERT hors vocabulaire dict	0,1365	0,0659
Oracle	0,7047	0,8150
Δ vs meilleur des deux	0,3184	0,0578

TAB. B.2 : Option B — régimes.

Régime	n	%	$P(\text{err.})$	D seul juste	S seul juste	Les deux justes
ACCORD	79	0,9	0,114	0	0	70
CONFLIT	246	2,9	0,138	73	139	0
D-SEUL	7092	82,5	0,102	6368	0	0
S-SEUL	413	4,8	0,133	0	358	0
AUCUN	769	8,9	1,000	0	0	0

Lecture : sans le dense sur la tête de vocabulaire, presque tout devient D-SEUL. L’option B ne peut pas porter un chapitre de résultats parallèle.

Annexe C

Exemple pédagogique : une note imaginaire de dix mentions

Pour ancrer les 71 / 41 / 30. Soit dix mentions gold. Les tickets sont fictifs, les proportions imitent la table A.

#	Surface	D	S	Régime
1	hypertension	HTA	HTA	ACCORD juste
2	CAD	CAD	CAD	ACCORD juste
3	diabetes	DT2	DT2	ACCORD juste
4	MI (ECG)	infarctus	infarctus	ACCORD faux
5	hypotension	hypotension	HTA	CONFLIT (D juste)
6	lap chole	—	cholécystectomie	S-SEUL juste
7	NPO	jeûne	—	D-SEUL juste
8	pcn	—	—	AUCUN
9	stable	—	—	AUCUN
10	ileus	occlus. intestinale (faux)	—	D-SEUL faux

La ligne 4 est un accord faux : les deux prédisent un infarctus, le gold est une insuffisance mitrale.

Erreurs (ni D ni S justes) : mentions 4, 8, 9, 10 $\rightarrow$ 4 erreurs.

File = non-accord = {5, 6, 7, 8, 9, 10} (et pas 4).

Erreurs dans la file : {8, 9, 10} $\rightarrow$ rappel d'erreurs $3/4 = 75\%$.

Dont silence {8, 9} = 50 points du total d'erreurs ; désaccord stricto sensu {10} = 25 points ; angle mort {4} = 25 points.

C'est la même arithmétique que $41 + 30 + 29$ sur 1 282 erreurs. Le 75 % de cet exemple n'est pas un exploit : deux des trois erreurs « attrapées » sont des silences.

Annexe D

Glossaire opérationnel

Ticket

Un quadruplet (`note_id`, `start`, `end`, `concept_id`) émis par un système.

Mention gold

Un quadruplet annoté. L'unité des tables de régimes.

Hit

Match de span ($\text{IoU} \geq 0,5$) et bon SCTID.

Erreur (file)

Mention gold sans hit *D* ni hit *S*.

File

Liste des mentions (gold, en laboratoire) dont le régime n'est pas ACCORD. Ce ne sont **pas** les bons accords. Ce sont les doutes.

Oracle

Sélecteur qui voit le gold. Plafond. Inutilisable en production.

mIoU

Macro IoU caractère par concept. Métrique challenge.

Rappel mention

Moyenne des hits. Métrique honnête pour l'oracle.

FSN-Lev

Distance de Levenshtein entre deux Fully Specified Names, tag sémantique retiré.
Descripteur des conflits, pas un linker.

Annexe E

Arborescence utile

```
snomedEL/  
  dictmethod/      # KIRIs publie (sans OMOP ici)  
  SnoBERT/         # pipeline + baseline  
  oracle_study/    # alignement, regimes, oracle, file  
    kiri.py  
    oracle.py  
    regimes.py  
    review_queue.py  
    output/  
memoire/latex2/    # ce manuscrit (memoire_2)
```

Annexe F

Compléments sur SNOMED CT et le périmètre

SNOMED CT distingue concepts, descriptions et relations. Un même concept a un Fully Specified Name unique et plusieurs synonymes. La post-coordination permettrait d'assembler « fracture » et « poignet gauche » ; le challenge l'interdit : un span, un identifiant pré-coordonné des trois branches. Nous n'évaluons donc pas la capacité d'un système à *composer*.

Les identifiants cités dans le texte pédagogique (HTA, etc.) sont des noms de commodité. Les tables numériques n'utilisent que des SCTID entiers issus des CSV.

Le snapshot challenge est daté (2023-05-31). Un SNOMED plus récent déplacerait des codes. Tous les systèmes comparés partagent le même snapshot d'identifiants. Les libellés FSN utilisés pour la distance d'édition (chapitre 5) sont lus sur le RF2 présent dans l'environnement (2026-02-01).

Annexe G

Compléments sur la métrique caractère

Soit C l'ensemble des concepts apparus dans le gold ou la prédiction. Pour chaque $c \in C$, on forme l'ensemble des offsets de caractères assignés à c dans la prédiction et dans le gold (union sur les notes). L'IoU de c est le Jaccard de ces deux ensembles. Le mIoU est la moyenne sur C . Un concept jamais prédit et présent une fois dans le gold a une IoU nulle et pèse autant qu'un concept fréquent. C'est voulu par le challenge (longue traîne). C'est aussi pourquoi un dictionnaire bruyant (beaucoup de FP sur des concepts rares) est sévèrement puni — et pourquoi l'oracle, qui n'émet que des VP, est flatté.

Annexe H

Jeux de nombres à ne pas mélanger

TAB. H.1 : Deux protocoles, deux mIoU SnoBERT. Ne pas les additionner.

Chiffre	Origine
0,4194	leaderboard privé challenge (autre split)
0,4903	notre hold-out 32 notes, pipeline complet
0,4202	KIRIs, leaderboard privé
0,3863	KIRIs, notre hold-out (reproduction partielle)

Annexe I

Remarques de reproductibilité statistique

Les 8 599 mentions ne sont pas indépendantes. Une note longue contribue plus. Un intervalle de confiance de moyenne mention-i.i.d. serait anti-conservateur. La procédure correcte, copiée sur JAMIA, est un bootstrap sur les 32 identifiants de notes : tirer 32 notes avec remise, recalculer mIoU, régimes, rappel d'erreurs, répéter 1 000 fois. Nous l'avons écrite comme limite, pas comme résultat. Aucune p -valeur n'est donc rapportée.