



Alignement sémantique

Ahmed Abatna

Contents

1	Introduction	3
2	Le stage : enrichir les requêtes de l'EDS	4
2.1	Contextualisation, extraction, filtre	4
2.2	Liaison à UMLS	5
2.3	Évaluation et constat	5
3	alignement sémantique sur des comptes rendus	6
3.1	Où la sortie peut se brancher	7
3.2	Explorer les méthodes d'alignement sémantique	7
3.3	Le projet : données, deux moteurs, résultats	8
3.3.1	L'approche dictionnaire	8
3.3.2	L'approche SnoBERT	9
3.3.3	Les interfaces de démonstration	9
3.4	Environnement de travail	10
3.5	Adapter le chantier au français : PARHAF	10
3.6	Augmented Mixup Procedure : banc d'essai	12
3.7	Le mémoire : comparaison, accords, file	13
4	Suite	14
5	Petit lexique	15
6	Livrables	15

1. Introduction

J'ai commencé à Enovacom par un stage lors de ma 3^e année du cycle ingénieur à l'École polytechnique. Au sein de la BL Valorisation des données, et précisément dans l'équipe d'Asma Rabaoui que je remercie énormément d'ailleurs de m'avoir encadré, j'ai travaillé sur l'enrichissement des requêtes dans un EDS comme eHOP : à partir d'une question tapée, il s'agissait de repérer les entités médicales, de les reformuler et de les ancrer dans un référentiel, pour rendre la recherche plus pertinente.

J'ai ensuite poursuivi, en alternance (Master 2 ISF, Dauphine–PSL), sur l'exploration de différentes approches d'alignement sémantique sur les **comptes rendus médicaux** : extraire les mentions et leur associer un code issu d'un référentiel comme SNOMED [7], en comparant une approche par dictionnaire et une approche fondée sur BERT.

Je remercie Asma Rabaoui pour son encadrement, du stage à l'alternance: la confiance qu'elle m'a accordée, les retours sur le travail, et la liberté laissée pour explorer. Je remercie également Mr. Patrice Grilli, directeur de notre BL, pour sa confiance, ainsi que Nour Idriss Pacha et les autres membres de l'équipe, pour l'accueil, les échanges enrichissants, et la place qui m'a été faite dans le travail de l'équipe.

2. Le stage : enrichir les requêtes de l'EDS

Un EDS rassemble ce que l'hôpital produit : données administratives, DPI, comptes rendus, biologie, imagerie. La promesse, c'est une vue consolidée pour le soin, le pilotage et la recherche. Encore faut-il pouvoir interroger ce stock autrement qu'avec les mots exacts de l'index.

Au moment du stage, la recherche fonctionnait surtout par mots-clés, parfois avec un thésaurus pour proposer des synonymes. Cela suffit tant que l'utilisateur tape le terme prévu. Un médecin dira « cardiopathie », un autre « maladie cardiaque » ; un chercheur tapera une expression plus fine. Personne n'emploiera forcément le libellé du thésaurus. S'y ajoutent les fautes (« diabète »), les abréviations, et les requêtes d'un seul mot, trop courtes pour lever une ambiguïté. Le moteur passe alors à côté.

L'objectif n'était pas de recoder les dossiers. Il s'agissait de concevoir, mettre en œuvre et évaluer un pipeline qui, à partir de la question saisie, identifie les entités médicales, les reformule, et les ancre dans un référentiel (UMLS [1]), pour que la recherche soit plus pertinente et plus complète. L'hypothèse de travail : enrichir la requête *en amont* de la recherche donne plus de prise qu'enrichir les documents une fois pour toutes, de manière statique.

Plusieurs pistes ont été écartées assez vite. Un NER supervisé figé suppose des catégories connues à l'avance, et des annotations qu'on n'avait pas sur ce cas d'usage. Un thésaurus statique ne suit pas le langage réel. Un outil comme SciSpaCy, conçu pour l'anglais biomédical, ne tient pas sur du français hospitalier, et demandait des ressources (GPU, RAM) hors cadre du stage. Ce qui a été retenu, c'est une chaîne hybride, en Python, découpée en modules interchangeable — pour pouvoir changer le LLM (local ou API) sans tout casser.




Figure 1: Chaîne du stage : la requête brute passe par le LLM (reformulation), le NER (entités), un filtre, puis le lien UMLS, et sort enrichie.

2.1. Contextualisation, extraction, filtre

Un LLM (QueryContextualizer) corrige les fautes, gère les synonymes, et allonge une requête trop courte. Dans le prototype, une question de moins de cinq mots est traitée comme sémantiquement pauvre : le modèle propose des reformulations, que l'on ajoute à la question d'origine avant de passer au NER. Une question trop courte devient une phrase qui porte le même sens. « Insuffisance cardiaque » peut ainsi devenir « le patient souffre d'une insuffisance cardiaque », et l'extraction a alors plus de prise.

GLiNER [10], en zéro-shot, repère ensuite maladies, traitements, examens. On ne réentraîne pas le modèle à chaque nouveau type : on lui donne les libellés à chercher. Ce choix vient du peu d’annotations disponibles chez Enovacom sur ce cas d’usage.

Chaque candidat est d’abord recalé par le LLM, puis un filtre CamemBERT-bio [9] (almanach/camembert-bio-base) décide s’il parle encore de la question. On encode la mention corrigée et la requête d’origine, on calcule le cosinus, et on ne garde le candidat que si ce score reste $\geq 0,5$. Une mention trop loin de ce qui a été tapé — un faux positif introduit par le LLM ou le NER — est écartée. Les doublons (*diabète* / *diabete*) partent ensuite au *fuzzy ratio* (deux écritures presque identiques, malgré une faute) et au stemming (on ramène le mot à sa racine : *cardiaques* et *cardiaque* comptent comme le même).

2.2. Liaison à UMLS

Une mention acceptée n’est pas encore un identifiant. CamemBERT-bio projette la mention et les libellés UMLS dans le même espace. Les vecteurs des concepts sont indexés une fois pour toutes avec FAISS [4] (recherche approchée, graphe HNSW). À l’interrogation, on ne calcule que le vecteur de la mention, on récupère les k plus proches libellés, et un vote majoritaire choisit le CUI — l’identifiant unique de concept. Si $k = 1$, le vote se réduit au plus proche voisin. Si $k = 3$ ou 5, plusieurs libellés peuvent pointer vers le même CUI : le vote évite qu’un voisin isolé, au mauvais sens ou à la mauvaise granularité, l’emporte tout seul.



Figure 2: Liaison UMLS : voisins, puis vote.

Table 1: Modules du prototype (Python, pile française).

Module	Rôle	Choix
QueryContextualizer	Fautes, synonymes, requêtes courtes	LLM local ou API
NER	Spans médicaux	GLiNER, zéro-shot
Filtre	Cohérence avec la requête	LLM, puis CamemBERT-bio, cosinus $\geq 0,5$
Dédup	Surfaces voisines	<i>fuzzy ratio</i> , stemming
MedicalIndex	Identifiant UMLS (CUI)	FAISS, vote majoritaire

2.3. Évaluation et constat

L’évaluation s’appuie sur QUAERO French Medical, un jeu d’annotations tirées de MEDLINE (résumés d’articles médicaux). L’hypothèse : ces groupes de mots médicaux peuvent, pour le test, tenir lieu de questions tapées par un utilisateur. On compte une bonne réponse seulement si le morceau de texte coïncide exactement avec l’annotation (mêmes bornes, même étiquette). On

calcule précision, rappel et F1 à l'extraction, et, pour la liaison, si le bon code figure parmi les k premiers proposés ($k = 1, 3$ ou 5) — uniquement sur les entités déjà bien trouvées, pour juger le lien à part. Les appels au LLM étaient trop lents pour tout mesurer dans le temps du stage. Il n'y a donc pas de tableau chiffré complet ; le constat ci-dessous vient d'une relecture manuelle sur une partie des phrases.

Table 2: Constat du stage (revue manuelle).

Volet	Constat
LLM	Rappel plus haut sur les requêtes courtes : la reformulation donne prise au NER.
Filtre	Précision plus haute : les candidats trop loin de la requête sont écartés.
UMLS / FAISS	Prototype opérationnel. Erreurs vues : polysémie (sens courant / médical) et granularité (diabète type 1 / type 2).

Ce stage a permis une architecture de requête, des modules qu'on peut remplacer un par un, et le réflexe de travailler en français (CamemBERT-bio, GLiNER). Il reste cependant à passer du code UMLS au code SNOMED, et à brancher cette chaîne dans la recherche de l'EDS.

3. alignement sémantique sur des comptes rendus

Après le stage, en alternance, le projet s'élargit. On ne part plus seulement d'une question tapée : on prend aussi la *note* (un compte rendu), et on en sort des mentions et un code. Plusieurs façons de dire la même chose doivent aboutir au même identifiant, stable d'un hôpital à l'autre : le même rôle que le code UMLS du stage, cette fois dans le compte rendu.

J'ai repris deux approches qui associent, à chaque mention du compte rendu, un identifiant médical : un dictionnaire, et un modèle de type BERT. Je les ai fait tourner sur les mêmes notes déjà annotées. Le même geste a ensuite été repris sur des comptes rendus français fictifs (PARHAF), que l'on peut partager en interne.

En parallèle, une autre équipe d'Orange cherchait à valider une approche de mixup pour des données venues de plusieurs sites : on mélange les représentations internes du modèle et on y ajoute un peu de bruit, afin de limiter ce qu'on peut reconstruire des données d'origine. J'ai entraîné mon modèle avec ce mélange, puis vérifié, sur les notes d'origine, si le lien vers un identifiant médical reste utilisable.

J'ai aussi travaillé, en parallèle, sur un mémoire. Si l'on prévoit de relire les résultats, et qu'on met en place une revue des mentions marquées, peut-on organiser cette relecture pour qu'une personne voie d'abord ce qui en vaut la peine ? C'est utile pour l'entreprise : tout revérifier n'est pas tenable. Les deux approches ne se trompent pas aux mêmes endroits ; là où elles sont d'accord, l'erreur est plus rare. On peut donc réduire la file, sans laisser de côté la plus grande partie des cas douteux.

3.1. Où la sortie peut se brancher

Le mémoire porte sur la relecture. Avant cela, la sortie elle-même — une mention et un code — peut servir à trois endroits. L'EDS veut interroger les comptes rendus par concept, pas seulement par mot-clé : le même fil que le stage, cette fois à partir du document. L'EIE (échange entre établissements) veut qualifier un dossier et retrouver la même information ailleurs. Un service interne peut n'exposer qu'un score et les cas à relire. Dans les trois cas, on ouvre une note et on en sort des mentions et des codes.




Figure 3: Trois portes produit. Brique amont : note → mentions + codes.

Trois difficultés reviennent. Une abréviation peut désigner deux choses différentes. Un même mot change de sens selon la phrase (« cold » : un rhume, ou simplement le froid). Le texte réel est bruité : fautes, mots collés, sauts de ligne. J'ai adapté deux approches SNOMED au contexte Enovacom — un dictionnaire et un modèle de type BERT — je les ai fait tourner sur les mêmes comptes rendus, et je les ai montrées.

3.2. Explorer les méthodes d'alignement sémantique

Le projet d'alternance, c'est d'adapter l'alignement SNOMED à l'entreprise : à partir d'un compte rendu, sortir les mentions et un code utilisable dans l'EDS. Le corpus de travail est un jeu de 272 résumés de sortie déjà annotés (MIMIC-IV, anglais, licence PhysioNet [3]) : 74 808 occurrences, 6 624 concepts, trois familles (constats, actes, anatomie). La tâche : le bon intervalle de caractères *et* le bon code. La métrique usuelle, le mIoU, mesure à quel point les bornes prédites recouvrent les bornes annotées, pour le bon code. Un mot de trop coûte.

Deux familles tiennent sur ce terrain. Un **dictionnaire** : on cherche une expression déjà connue, on récupère le code. Un **modèle BERT** (SnoBERT) : on repère d'abord les mots médicaux, puis on cherche le concept SNOMED le plus proche. Je les ai tous les deux mis en route chez Enovacom, avec les mêmes interfaces de lecture. La comparaison fine — accord, conflit, file de relecture — est un travail de mémoire, traité plus loin, pas le livrable du projet d'adaptation.




Figure 4: Même sortie que le stage (un identifiant), autre entrée : le CR.

3.3. Le projet : données, deux moteurs, résultats

Les données du projet sont ces 272 résumés : texte réel d'hôpital, déjà annoté. Le code utilisé est le dictionnaire (`dictmethod/`) et SnoBERT (`SnoBERT/`).

En une phrase : on ouvre un compte rendu, on souligne les mots médicaux, on leur colle un code SNOMED. Deux recettes le font, adaptées pour être montrées et utilisées en interne.

3.3.1. L'approche dictionnaire

C'est un lookup : on cherche une expression dans une table, on récupère un code — ou rien. On construit la table ainsi : telle rubrique de la note, telle expression, tel code. La clé est là : le code sort. Un dictionnaire ne s'entraîne pas comme un réseau de neurones : il n'y a pas d'époques ni de perte à minimiser. Pour le pousser au maximum, je l'ai donc construit à partir de **toutes** les notes annotées, plus un filtre sur les clés trop ambiguës, les synonymes OMOP / SNOMED et une table d'abréviations. Le score dit surtout d'où vient la clé : justesse historique si elle a été vue, 1 si elle vient du référentiel. Levenshtein (distance d'édition entre deux chaînes) sert d'audit, pas de score produit.




Figure 5: Chaîne du dictionnaire, construit sur toutes les notes. VM CPU, réponse immédiate.

Deux limites se voient tout de suite. Si deux mots sont collés, la table peut connaître l'un des deux et quand même le refuser, parce qu'elle cherche une expression séparée du reste. Si les bornes ne coïncident pas, l'interface compte à la fois un ajout et un manque, même quand le sens est le même : « tolerating a regular diet » contre « regular diet ».

3.3.2. L'approche SnoBERT

Deux étapes. Un BiomedBERT — un modèle de langue entraîné sur des textes médicaux anglais — délimite ce qui ressemble à un constat, un acte ou une anatomie (NER : repérer les mots médicaux dans le texte). Chaque segment devient un vecteur (SapBERT [5]) ; on cherche le concept SNOMED le plus proche parmi environ 200 000 identifiants des trois familles, puis un dictionnaire statique rattrape des formulations fréquentes. Le code d'entraînement est `SnoBERT/src/main.py` et `configs/snom.yaml` ; il demande une carte graphique (GPU).




Figure 6: Pipeline SnoBERT. GPU à l'entraînement. Le run démo : haute précision, rappel plus bas sur les constats.

Côté usage, c'est l'inverse du dictionnaire : il généralise à des formulations jamais vues, mais il manque des constats (sur la note 10989002-DS-3, 90 spans rouges pour 128 verts). La lecture reprend les mêmes couleurs et le même clic.

3.3.3. Les interfaces de démonstration

Même geste sur les deux moteurs : ouvrir une note, voir le vert (même span), le jaune (ajout à relire), le rouge (manque). Un clic sur une mention cadre le span, sans recharger la page.




Figure 7: Lecture commune des trois interfaces.

Les bandeaux sont des lectures locales, deux définitions différentes. Le dictionnaire compte une correspondance de bornes exactes ; SnoBERT compte un chevauchement d'au moins un caractère. On ne les compare pas.

Table 3: Bandeaux (curseur à 0 : tout est affiché, rien n'est filtré).

Interface	Notes	P	R	F1
Dictionnaire (bornes exactes)	272	82 %	90 %	86 %
SnoBERT (chevauchement)	32	90 %	59 %	71 %

Table 4: Exemples de notes. V, J, R : vert, jaune, rouge.

Moteur	Note	V	J	R	Lecture
Dict	10043750-DS-6	151	28	18	12/18 rouges dans un jaune
Dict	10060142-DS-9	75	19	11	10/11 = bornes
SnoBERT	10989002-DS-3	128	41	90	constats manqués
SnoBERT	12986424-DS-6	78	6	36	même profil, plus court

Dans le premier tableau, P est la précision : parmi les mentions proposées, la part qui tombe juste. R est le rappel : parmi les mentions à trouver, la part effectivement trouvée. F1 résume les deux en un seul chiffre. Le curseur à 0 laisse passer toutes les propositions, même les moins sûres. Les deux lignes ne se comparent pas : le dictionnaire exige les mêmes bornes, SnoBERT un simple chevauchement, et le nombre de notes n'est pas le même.

Dans le second, V, J et R comptent les couleurs d'une note. Vert : le span trouvé coïncide avec l'annotation. Jaune : un ajout à relire. Rouge : un manque. Ce R-là n'est pas le rappel du tableau précédent.

3.4. Environnement de travail

Le dictionnaire tourne sur une machine CPU : table en mémoire, réponse immédiate. Pas besoin de carte graphique pour une note et un lookup.

SnoBERT et le modèle français, eux, s'entraînent sur GPU — une carte qui accélère les calculs du réseau de neurones (`torch.cuda` dans `SnoBERT/src/main.py` et `main_parhaf.py`). Quand je n'avais pas accès à une carte graphique Enovacom, j'ai lancé les runs sur des ordinateurs de l'école. C'est un point d'investissement personnel : sans ça, pas de SnoBERT réentraîné, pas de CamemBERT-bio infectiologie, pas de grille de l'Augmented Mixup Procedure.

3.5. Adapter le chantier au français : PARHAF

MIMIC est anglais, américain, partageable sous licence PhysioNet. Le terrain Enovacom est français. PARHAF [8] — corpus de comptes rendus *factifs* (patients inventés, texte réaliste), porté par le HDH et PARTAGES — est le pont : on peut le partager en interne, sans dossier patient réel. Les fichiers sont sous `parhaf/csv/` ; le modèle sous `snomedEL/SnoBERT/` (`main_parhaf.py`, `configs/parhaf_ner.yaml`).



Figure 8: PARHAF est le texte. Patients inventés, partageables.

Cinq jeux annotés publics, 12 461 spans experts, 2 624 relations (parhaf/csv/ : infectiology_spans.csv, relations, métadonnées). L'infectiologie est le jeu le plus riche pour un premier modèle : 134 comptes rendus, 3 576 mentions (infection, germe, site) et 1 713 liens entre elles. Un span, c'est un intervalle de caractères dans le CR, avec un type — pas encore un code SNOMED.

Table 5: Jeux annotés publics PARHAF.

Jeu	Docs	Spans	Contenu
Pseudo	509	6 976	noms, dates, lieux
Infectiologie	134	3 576	infection, germe, site + liens
Biomarqueurs	152	1 698	biomarqueur ↔ résultat
RTT	108	~100	réponse au traitement
Conclusion	—	108 manuels	

L'idée du projet français : reprendre le même geste qu'en anglais (repérer un span, lui donner un type), mais sur du texte hospitalier français. On ne prédit pas encore un code SNOMED : on prédit une étiquette du projet HDH (infection, germe, site...).

J'ai entraîné un CamemBERT-bio (almanach/camembert-bio-base — modèle de langue français, pré-entraîné sur du biomédical) à repérer ces mentions dans les 134 CR d'infectiologie : 107 en train, 27 en validation (dev officiel). 50 époques exécutées ; le meilleur point est l'époque 16 (dernier IoU en hausse — l'IoU mesure le chevauchement entre ce que le modèle souligne et ce que l'annotateur a souligné). Le score retenu est 0,779.

Table 6: Modèle infectiologie. IoU token moyen, 5 classes après fusion B/I, validation uniquement.

Champ	Valeur
Encodeur	CamemBERT-bio-base
Train / val	107 / 27 CR
Score retenu	0,779 (IoU token)
Époque	16 / 50
Étiquettes	celles du projet HDH

La lecture reprend le même geste : vert, jaune, rouge, et un clic sur la mention.

Limites, telles quelles. Le 0,779 est un IoU *token*, pas un F1 de spans aux bornes exactes, et encore moins un mIoU SNOMED. Les étiquettes sont celles du projet HDH (infection, germe, site...), pas des SCTID. Le corpus est fictif et petit : 27 CR de validation. Un passage à l'hôpital demandera un calage — étiquettes établissement, puis, si l'on veut interroger l'EDS par concept, un mapping vers SNOMED ou vers les codes qualité. Cette forme structurée rejoint le travail déjà mené sur la

qualité des données. Ces contrôles — complétude, validité, cohérence, précision, unicité — portent surtout sur des données déjà structurées. Le compte rendu, lui, reste du texte libre. L'extraction le rend lisible de la même façon : une mention, un type, un code, un score. On peut alors étendre les mêmes contrôles à des documents qui ne l'étaient pas.




Figure 9: Du texte libre au structuré, puis aux contrôles de qualité.

PARHAF est un terrain pour cela. Une mention « infection » reliée à un germe donne prise à la complétude et à la cohérence : l'infection est-elle documentée, et le germe va-t-il avec ? Le calage vers les codes de l'établissement reste à faire.

3.6. Augmented Mixup Procedure : banc d'essai

L'*Augmented Mixup Procedure for Privacy-Preserving Collaborative Training* [6] est le travail d'une autre équipe : mélanger les vecteurs internes d'un modèle à l'entraînement, avec un peu de bruit, pour viser plus tard un apprentissage entre établissements sans tout partager. J'ai servi de banc d'essai sur *mon* moteur SnoBERT. Le mélange (mixup) n'agit que pendant l'entraînement du NER (SnoBERT/src/mixup.py, branché dans src/train.py). Le lieu (SapBERT + dictionnaire) reste inchangé. On mesure ensuite le linking sur des notes d'origine, pas sur des notes mélangées.




Figure 10: Le mixup agit à l'entraînement du NER.

Table 7: mIoU EL, hold-out. Mixup : moyenne de 3 graines. $\alpha = 0,7$.

Bras	mIoU	Lecture
Baseline (sans mixup)	0,4903	référence
$\tau = 1 / 0,1 / 0,01$	0,494–0,497	utilité préservée
$\tau = 0,001$	0,416	bruit trop fort

Le paramètre τ règle l'intensité du bruit : plus il est petit, plus on mélange fort. Lecture manager : un bruit modéré (τ entre 1 et 0,01) ne casse pas le linking ; un bruit trop fort ($\tau = 0,001$) si. Ce n'est

pas une preuve de confidentialité (on n'a pas attaqué le modèle), ni un protocole « deux hôpitaux ». Attaques et protocole collaboratif : à l'équipe qui porte cette procédure.

3.7. Le mémoire : comparaison, accords, file

Le mémoire ISF (Dauphine) n'est pas le projet d'adaptation. Le projet met en route le dictionnaire, sur toutes les notes, et SnoBERT. Le mémoire part d'un constat déjà publié, pour ne pas refaire un modèle que l'état de l'art a déjà écarté.

Davidson et al. [2] comparent trois façons de lier une mention à un concept SNOMED : un dictionnaire, un encodeur, un décodeur. Au niveau du *concept*, les deux premiers font jeu égal (0,420 et 0,419 ; les intervalles de confiance se recouvrent). Un vote majoritaire des trois n'ajoute presque rien : 0,442, soit +0,022. Pondéré par la fréquence des concepts, le vote bouge encore moins (0,626 contre 0,619). L'article le qualifie lui-même de gain modeste. Un modèle de plus, qui voterait toujours, ne dépasse donc pas ce résultat.

Ce vote fusionne tout. Il ne dit pas quelle mention relire, ni si les moteurs se trompent à des endroits différents. C'est la question du mémoire : que peut-on décider, mention par mention, quand les deux moteurs ne disent pas la même chose. Le code de cette étude est `snomedEL/oracle_study/`.

Pour cette mesure, le dictionnaire de l'étude est construit seulement sur les notes d'apprentissage (240 notes), et on regarde 32 notes mises de côté (8 599 mentions). Ce n'est pas le dictionnaire du projet, qui, lui, utilise toutes les notes.

Table 8: Mémoire. 32 notes, 8 599 mentions. Oracle = on prend le ticket juste s'il existe (plafond, pas un troisième modèle).

Système	mIoU caractère	Rappel mention
Dictionnaire (notes d'apprentissage)	0,449	0,774
SnoBERT	0,490	0,768
Oracle	0,739	0,853
Écart vs meilleur seul	+0,25	+7,9 pts

Le chiffre utile, c'est le rappel : **+7,9 points** si l'on sait choisir, à chaque mention, le moteur qui a raison. 502 mentions justes seulement chez le dictionnaire, 493 seulement chez SnoBERT.

Table 9: Régimes du mémoire. La file = tout sauf l'accord (27,5 % du volume, 75,6 % des erreurs).

Régime	<i>n</i>	%	Erreur	Juste d'un seul côté
Accord	6 232	72,5	5,0 %	—
Conflit	466	5,4	10,5 %	229 <i>D</i> / 188 <i>S</i>
Dictionnaire seul	618	7,2	18,8 %	502
SnoBERT seul	629	7,3	21,6 %	493
Silence	654	7,6	100 %	—

Sur 72,5 % des mentions, les deux moteurs sont d'accord et l'erreur est basse (5 %). La **file** du mémoire, c'est le reste : 2 367 mentions (27,5 %), qui concentrent 75,6 % des erreurs. On émet l'union, on relit le désaccord. Ce n'est pas un vote, et ce n'est pas un livrable du projet d'alignement : c'est une façon de réduire la relecture si, plus tard, le travail sur la qualité des données veut voir d'abord les cas incertains.

Table 10: File du mémoire : émettre l'union, relire le désaccord.

Quantité	Valeur
Mentions / erreurs	8 599 / 1 264
File	2 367 (27,5 %)
Erreurs dans la file	75,6 %
Accords faux (hors file)	309
Silences dans la file	654

L'apport n'est pas un troisième moteur. JAMIA [2] a déjà mesuré le vote, au grain du concept, et le gain est faible. Ici, l'oracle n'est qu'un plafond : il sait après coup quel moteur avait raison, ce n'est pas une méthode qu'on déploie. Le chiffre utile est le rappel de mentions, +7,9 points (0,853 contre 0,774 et 0,768). Le mIoU de ce plafond (0,74) ne compte que des mentions justes, il est donc gonflé, et on ne le prend pas comme un gain. Sans vérité terrain, l'accord suffit à autre chose : la relecture peut se limiter au quart des mentions qui concentre les trois quarts des erreurs.

4. Suite

La lecture d'une note est déjà en place. Ce qui reste tient en trois pas, du plus proche au plus lointain.

Le plus proche est PARHAF. Le score de 0,779 mesure un chevauchement de tokens, pas des bornes exactes, et les étiquettes sont celles du projet HDH, pas des codes utilisables dans l'EDS. Passer à un F1 de spans, puis relier ces étiquettes aux codes qualité ou à SNOMED, est ce qui ouvre une recherche par concept sur des comptes rendus français.

Ensuite, si l'on s'en sert, la file du mémoire peut nourrir le travail sur la qualité des données. Elle concentre la plupart des erreurs : une relecture peut donc commencer par les désaccords, plutôt que par tout le document. Ce n'est pas le livrable d'adaptation déjà en place.

Pour l'Augmented Mixup Procedure, le banc montre qu'un bruit modéré laisse le lien vers l'identifiant utilisable sur les notes d'origine. Le protocole entre établissements, et toute démonstration de confidentialité, restent à l'équipe qui porte la procédure.

5. Petit lexique

Mot	Sens ici
Alignement sémantique	Coller un identifiant stable à un morceau de texte.
SNOMED / CUI	Code partagé (hôpital à hôpital), pas un synonyme libre.
NER	Repérer dans le texte les mots médicaux.
mIoU	Accord des bornes <i>et</i> du code, moyenné.
Rappel	Part de ce qui était à trouver et qu'on a trouvé.
GPU	Carte graphique, pour entraîner un réseau.
Mixup	Mélange de vecteurs internes à l'entraînement.
PARHAF	Comptes rendus français fictifs, partageables.

6. Livrables

Le projet d'adaptation livre deux moteurs sur les mêmes comptes rendus. Le dictionnaire, construit sur toutes les notes, répond tout de suite sans carte graphique : on retrouve un code déjà vu. SnoBERT, lui, généralise à des formulations jamais vues. Les deux sortent une mention et un identifiant.

Sur le français, le modèle CamemBERT-bio entraîné sur l'infectiologie PARHAF atteint 0,779 en recouvrement de tokens. C'est une extraction partageable en interne, sur des patients inventés. Ce n'est pas encore un code SNOMED.

Le banc sur l'Augmented Mixup Procedure est un test d'utilité pour l'autre équipe : avec un bruit modéré, le linking sur les notes d'origine tient. Il ne démontre pas qu'on ne peut pas reconstruire les données.

L'étude du mémoire est à part. Elle dit comment lire les deux moteurs ensemble : là où ils sont d'accord, l'erreur est rare, et la file qui reste rassemble l'essentiel des cas douteux.

Bibliographie

- [1] Olivier Bodenreider. The Unified Medical Language System (UMLS): integrating biomedical terminology. *Nucleic Acids Research*, 32(suppl_1):D267–D270, 2004.
- [2] Rory Davidson, Will Hardman, Guy Amit, Yonatan Bilu, Vincenzo Della Mea, Aleksandr Galaida, Irena Girshovitz, Mikhail Kulyabin, Mihai Horia Popescu, Kevin Roitero, Gleb Sokolov, and Chen Yanover. SNOMED CT entity linking challenge. *Journal of the American Medical Informatics Association*, 32(9):1397–1406, 2025.
- [3] Alistair E. W. Johnson, Tom J. Pollard, Steven Horng, Leo Anthony Celi, and Roger G. Mark. MIMIC-IV-Note: Deidentified free-text clinical notes. PhysioNet, 2023.
- [4] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535–547, 2021.
- [5] Fangyu Liu, Ehsan Shareghi, Zaiqiao Meng, Marco Basaldella, and Nigel Collier. Self-alignment pretraining for biomedical entity representations. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics*, pages 4228–4238, 2021.
- [6] Mihail-Iulian Pleșa, Fabrice Clérot, Simona Elena David, and Robert Poenaru. Augmented mixup procedure for privacy-preserving collaborative training. *Transactions on Machine Learning Research*, 2026. <https://openreview.net/forum?id=1SrZyNgmpY>.
- [7] SNOMED International. SNOMED CT. <https://www.snomed.org>, 2025.
- [8] Xavier Tannier, Salam Abbara, Rémi Flicoteaux, Youness Khalil, Aurélie Névél, Pierre Zweigenbaum, and Emmanuel Bacry. PARHAF, a human-authored corpus of clinical reports for fictitious patients in French. arXiv:2603.20494, 2026.
- [9] Rian Touchent and Éric de la Clergerie. CamemBERT-bio: Leveraging continual pre-training for cost-effective models on French biomedical data. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING)*, pages 2692–2701, 2024.
- [10] Urchade Zaratiana, Nadi Tomeh, Pierre Holat, and Thierry Charnois. GLiNER: Generalist model for named entity recognition using bidirectional transformer. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics*, pages 5364–5376, 2024.